

Aplicação de um modelo de rede neural artificial para predições de ações na bolsa de valores NASDAQ.

Fernando Demarchi Natividade Luiz; Valmei Abreu Júnior;
e-mails: nativanando@gmail.com; valmeijr@gmail.com;

RESUMO

Este artigo descreve um estudo de uma subárea da Inteligência Computacional chamada Redes Neurais Artificiais e sua aplicabilidade no mercado eletrônico financeiro. Também são expostas neste trabalho, ferramentas que auxiliam o desenvolvimento destas técnicas de forma eficiente, utilizando a linguagem de programação Python e suas bibliotecas de desenvolvimento, além de contextualizar como funciona, teoricamente, esses modelos de redes, que vêm ganhando destaque em diversas aplicações do contexto social.

Palavras-chave: Inteligência Artificial. Redes Neurais.

1. Introdução

A informatização do mercado acionário, que permite a movimentação de compra e venda de ações de forma eletrônica e automática, tornou-se fundamental ao longo das últimas décadas, gerando uma série de mudanças na forma em que as negociações são realizadas, se comparado ao modelo anterior, onde as movimentações aconteciam em uma unidade central, com a presença física dos investidores.

Dessa maneira, uma abordagem que vem ganhando destaque, dentre as pesquisas referentes à predição de cotações futuras que utilizam séries temporais, são as Redes Neurais Artificiais (RNAs). A capacidade das RNAs em trabalhar com uma quantidade significativa de variáveis simultâneas, além da composição de sua estrutura maciçamente paralela e distribuída, evidenciam sua alta escala de poder computacional, concedendo-as habilidades de aprendizado e generalização de funções. Estas duas capacidades de processamento de informação, tornam possíveis para as RNAs resolver problemas de grande escala que, usando o processamento digital convencional, são consideradas computacionalmente inviáveis e intratáveis (ELPINIKI; KATARZYNA, 2016; HAYKIN, 2000).

Tendo em vista as diversas aplicabilidades de RNAs para realizar análise de dados, atribui-se, como objetivo deste trabalho, realizar a predição no valor de abertura das ações de empresas presentes na bolsa de valores *National Association of Securities Dealers Automated Quotation System* (NASDAQ), utilizando um modelo de RNA proposto, com o intuito de validar sua acurácia e capacidade de precisão para o presente contexto.

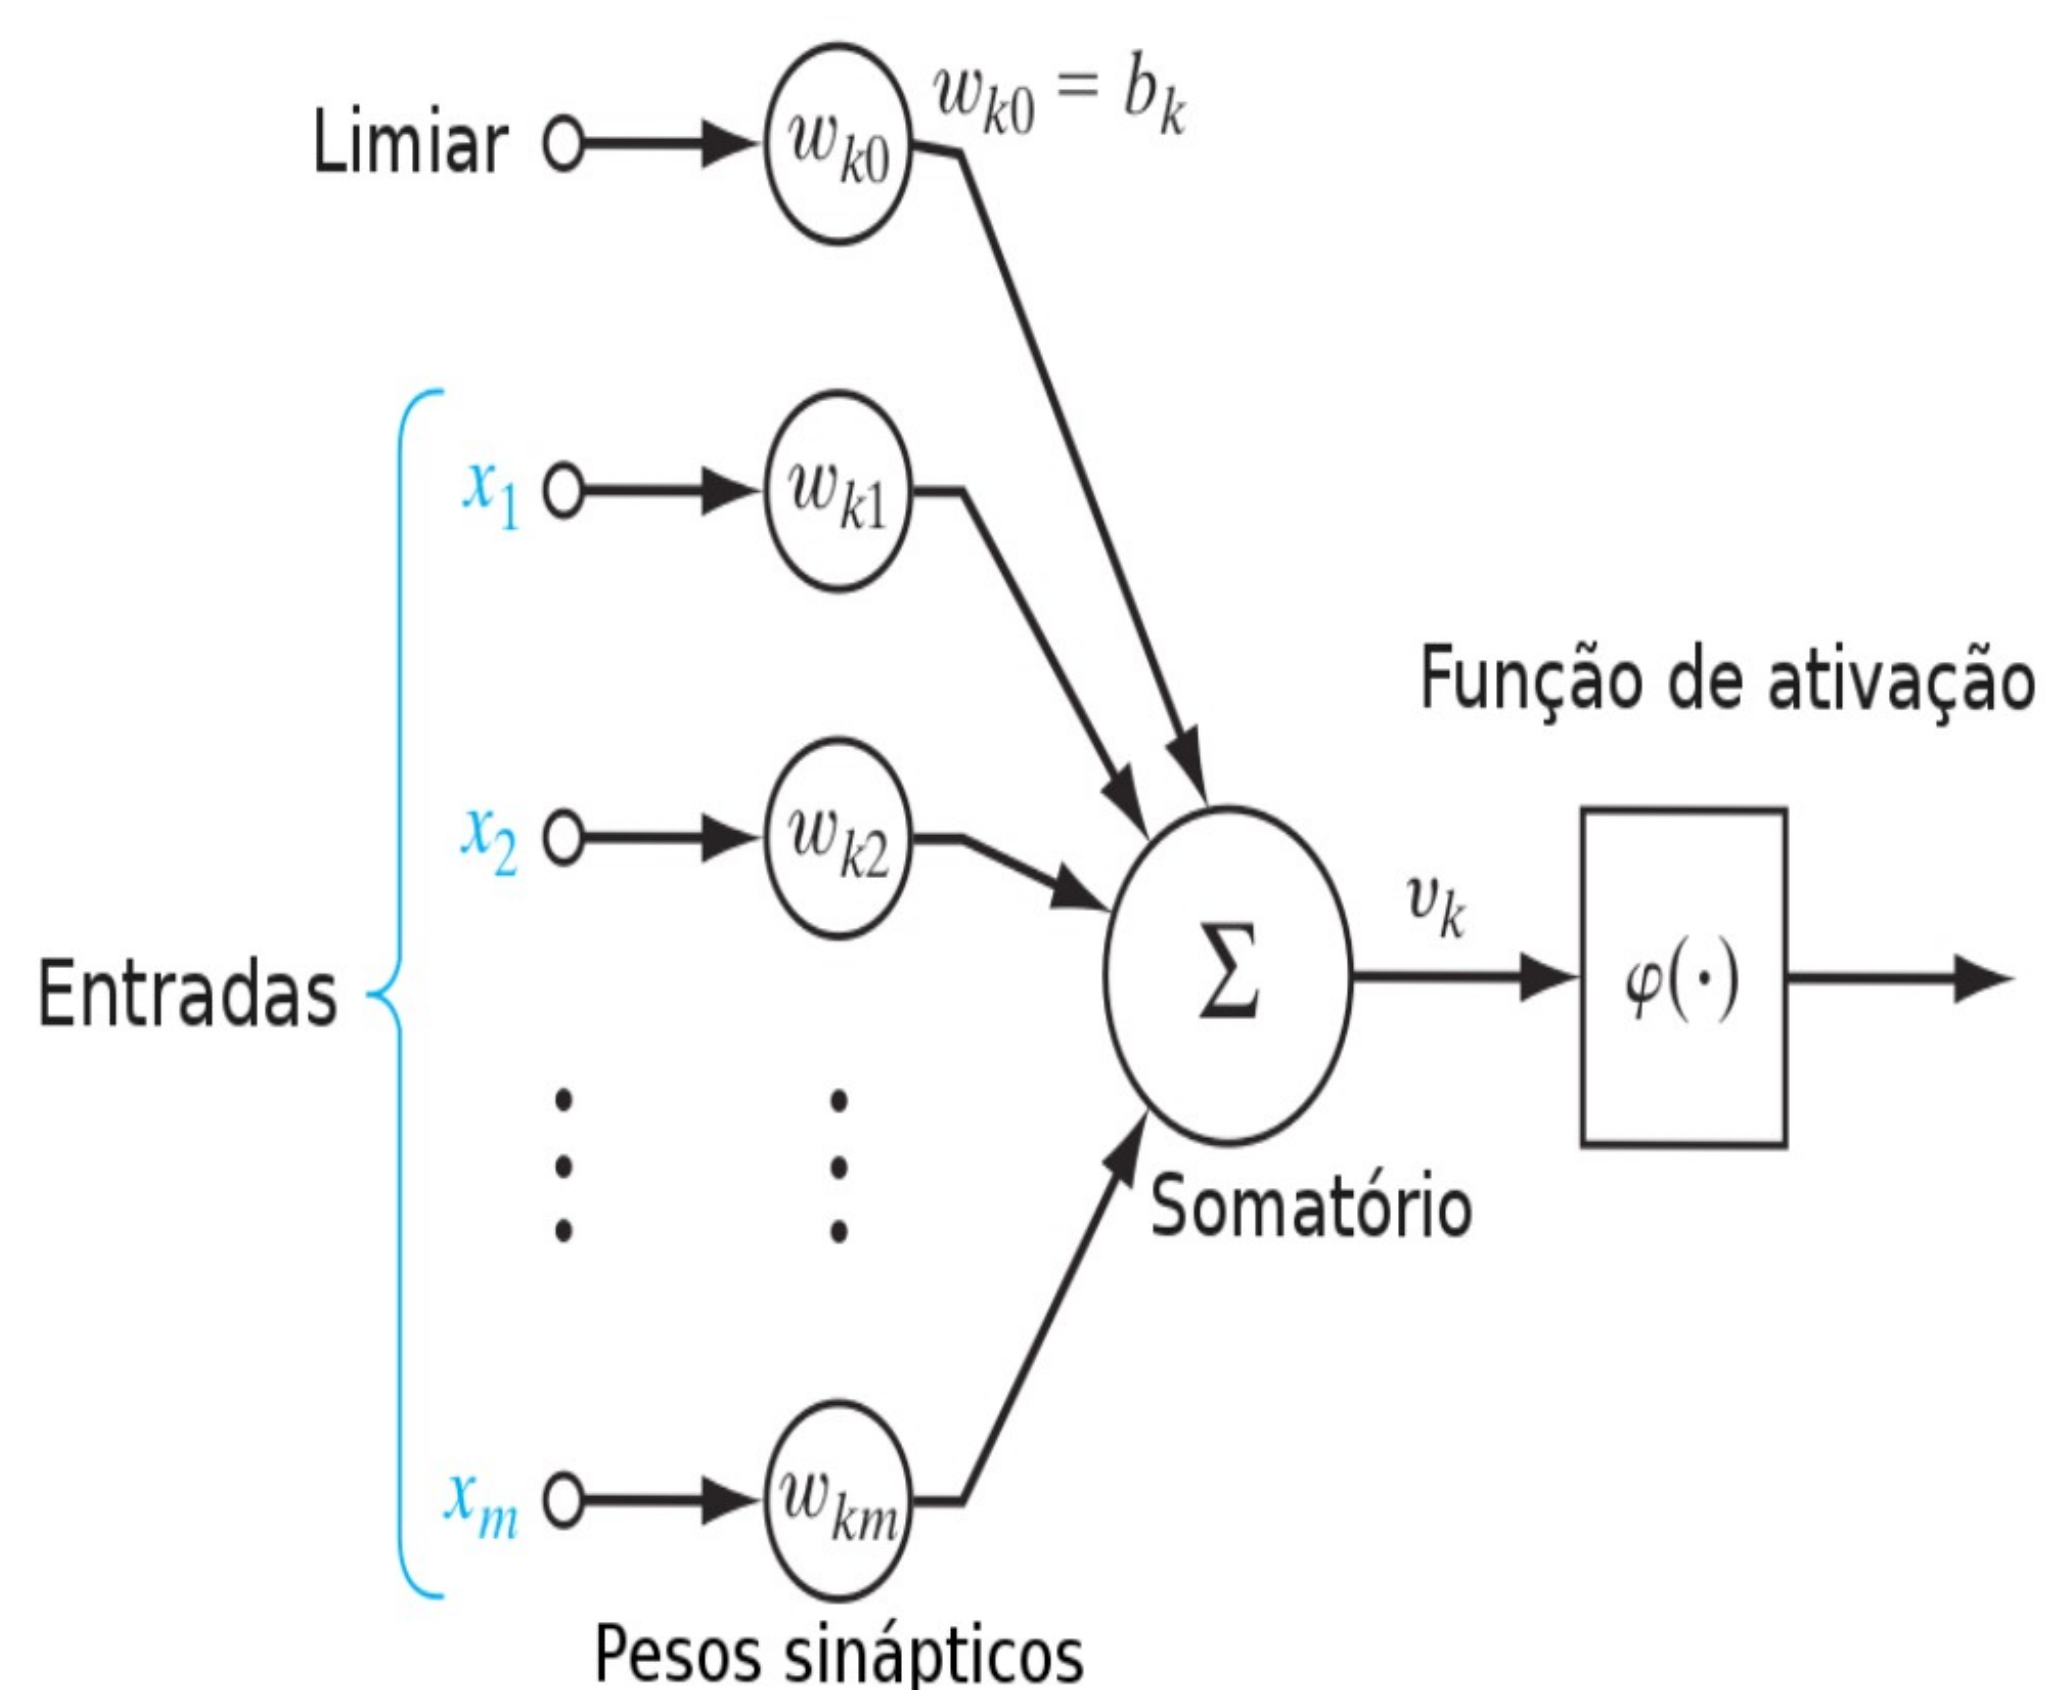


Figura 1 – Representação de uma Rede Neural Artificial.

4. Fundamentação teórica

Os neurônios são células que desempenham o papel de conduzir os impulsos nervosos. Estas células especializadas são, portanto, as unidades básicas do sistema que processa as informações e estímulos de um cérebro (LENT, 2001). A estrutura de um neurônio artificial segue os mesmos conceitos relacionados aos neurônios biológicos, buscando realizar as mesmas funções, utilizando-se de conceitos matemáticos, aritméticos e de tecnologias computacionais.

A arquitetura de uma RNA pode ser classificada pela quantidade de camadas ocultas e pelo sentido do fluxo de dados. Em relação ao número de camadas ocultas, ela pode ser de camada única (*single-layer*) ou multicamadas (*multilayer*). Quanto ao sentido do fluxo de dados, ela pode ser alimentada adiante (*feedforward*) ou recorrente (*feedback*) (MENDONÇA NETO, 2014).

O processamento em cada neurônio se dá através da função de ativação. A escolha da função de ativação de uma RNA é um processo de grande relevância, uma vez que esta função define como devem ser tratados seus dados de entrada. As funções de ativação podem ser classificadas como lineares ou não lineares. Sendo assim, destacam-se os modelos de funções: limiar, sigmóide e tangente hiperbólica (HAYKIN, 2000).

O treinamento de uma RNA consiste em minimizar uma função de custo, através de um algoritmo, cujos valores iniciais são escolhidos aleatoriamente com o objetivo de facilitar a busca pelo valor mínimo da função da amostra de treinamento, através de iterações (HAYKIN, 2000).

Para adquirir conhecimento, uma RNA requer um processo de inúmeras iterações, absorvendo os conhecimentos sobre o comportamento e relacionamento dos dados a cada ciclo e armazenando os ajustes realizados nos pesos sinápticos de cada neurônio (MENDONÇA NETO, 2014). Segundo Haykin (2000), os modelos de aprendizagem utilizados no treinamento de RNAs são conhecidos como aprendizagem supervisionada e aprendizagem não supervisionada. No modelo de aprendizagem supervisionada, o acompanhamento dos resultados é orientado constantemente durante o processo de treinamento da rede. Já no modelo de aprendizagem não supervisionada, não há supervisão dos dados processados.

3. AMBIENTE DE DESENVOLVIMENTO

Ferramentas utilizadas:

Python 3.6.0 como linguagem de programação
Biblioteca Pandas e Google Finance para coleta dos dados
Biblioteca PyBrain para a implementação do modelo de RNA

Métodos utilizados:

Arquitetura: Uma camada de entrada (8 variáveis), uma camada oculta com 13 neurônios e uma camada de saída, caracterizado pelo valor da predição;

Algoritmo de treinamento: Retropropagação;

Função de ativação: Sigmoid;

Função de custo: Erro quadrático médio;

Período de treinamento: 09/04/2001 até 21/08/2017.

4. Resultados

A partir do período treinado pela rede, foram realizados testes para os sete dias posteriores ao limite final da base de dados. A empresa utilizada foi a Intel Corporation. O período de teste foi de 23/08/2017 até 31/08/2017. No cenário da Intel Corporation, os resultados das predições, em todos os casos, não excedeu 0,72% de erro, se comparado ao valor real da ação. Analisando o período como um todo, a média dos 7 dias resultou em uma base de teste com aproximadamente 0,25% de erro. A tabela 1 demonstra os resultados obtidos.

Data	Valor esperado	Predição	Erro (%)
23/08/2017	34.54	34.77	0,66
24/08/2017	34.70	34.72	0,057
25/08/2017	34.82	34.81	0,028
28/08/2017	34.78	34.79	0,028
29/08/2017	34.51	34.76	0,72
30/08/2017	34.75	34.81	0,17
31/08/2017	34.94	34.98	0,11

Tabela 1 – Resultados obtidos nas ações da Intel Corporation.

5. Conclusão

Tendo em vista os resultados obtidos pelo modelo proposto, pode-se observar a alta capacidade de precisão das RNAs aplicada à predições no mercado acionário. Um ponto que se destaca, é a capacidade de acuracidade a longo prazo demonstrada pela rede, não decaindo sua taxa de acerto à uma quantidade significativa de dias, proporcionando uma análise mais profunda para um determinado período.

Também é importante evidenciar o escopo de aplicabilidade do modelo da RNA desenvolvido, podendo estar presente em análises para o ramo imobiliário e, também, à diversas áreas que operam com um modelo de dados similar ao utilizado aqui.

REFERÊNCIAS

ELPINIKI, I. P.; KATARZYNA, P. A two-stage model for time series prediction based on fuzzy cognitive maps and neural networks. Neurocomputing, 2016.

GAMBOGI, J. A. Aplicação de redes neurais artificiais na tomada de decisão no mercado de ações. Dissertação (Mestrado) — Universidade de São Paulo, São Paulo, 2013.

HAYKIN, S. Redes neurais: princípios e prática. Bookman, p. 903, 2000.

LENT, R. Cem bilhões de neurônios. Conceitos fundamentais de neurociência. Rio de Janeiro, 2001.

MENDONÇA NETO, J. N. Fractais e redes neurais artificiais aplicados à previsão de retorno de ativos financeiros brasileiros. 181 p. Dissertação (Mestrado) — Universidade de São Paulo, São Paulo, 2014.