



FÁBIO MARITAN PEREIRA

**REDES NEURAIS ARTIFICIAIS PARA
PREDIÇÃO NO MERCADO ACIONÁRIO
BRASILEIRO**

LAVRAS – MG

2014

FÁBIO MARITAN PEREIRA

**REDES NEURAIAS ARTIFICIAIS PARA PREDIÇÃO NO MERCADO
ACIONÁRIO BRASILEIRO**

Trabalho de conclusão de curso apresentado ao
Departamento de Ciência da Computação para
obtenção do título de Bacharel em Sistemas de
Informação

Orientador

Prof. DSc. Joaquim Quinteiro Uchôa

LAVRAS – MG

2014

FÁBIO MARITAN PEREIRA

**REDES NEURAIS ARTIFICIAIS COM REGULARIZAÇÃO BAYESIANA
PARA PREDIÇÃO NO MERCADO ACIONÁRIO BRASILEIRO**

Trabalho de conclusão de curso apresentado ao
Departamento de Ciência da Computação para
obtenção do título de Bacharel em Sistemas de
Informação

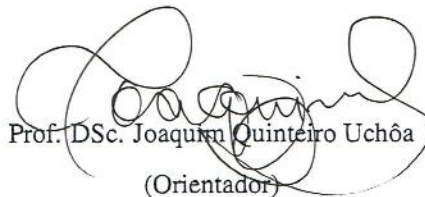
APROVADA em 11 de Fevereiro de 2014.


Prof. DSc. Raphael Winckler de Bettio

UFLA


Prof. DSc. Wilian Soares Lacerda

UFLA


Prof. DSc. Joaquim Quinteiro Uchôa
(Orientador)

LAVRAS – MG

2014

Dedico este trabalho a todas oportunidades ainda não abraçadas.

AGRADECIMENTOS

Uma série de duras batalhas acaba para que ocorra a concretização de um sonho, uma vitória maior. O momento é de agradecer àqueles que ajudaram a tornar o sonho em realidade. Agradecer a Deus pela luz de sempre. Aos meus pais pelo amor e apoio incondicional, pelos exemplos de bons valores, pelo senso e por toda confiança depositada. Aos meus irmãos e toda minha família que sempre acreditaram em meu potencial. A minha companheira e namorada por todo o amor, pela parceria nos melhores e piores momentos, pelo foco e equilíbrio proporcionados. Devo brindar também a fortuna que é ter verdadeiros amigos, uma força incomparável, irmãos que escolhemos. Aos professores pelo conhecimento adquirido e oportunidades. Ao orientador deste trabalho pela confiança, liberdade, atenção e suporte. Uma menção honrosa aos amigos-irmãos República Baviera pela experiência inigualável de convivência.

A persistência é o menor caminho do êxito.

(Charles Chaplin)

RESUMO

A predição no mercado acionário é um desafio recorrente na comunidade científica internacional. Ao longo das últimas duas décadas, técnicas de aprendizado de máquina e inteligência computacional vêm sendo aplicadas para destrinchar a complexidade das séries temporais de preços de ações. Dentre as técnicas, as redes neurais artificiais, que buscam simular computacionalmente a forma de aprendizado do cérebro humano, têm mostrado evoluções consideráveis. A regularização *bayesiana* é um método aplicado na fase de treinamento de redes neurais que visa aprimorar a capacidade de generalização da mesma. O presente trabalho apresenta um modelo de previsão baseado em uma rede neural para predição do valor de fechamento do próximo dia dos mais relevantes papeis negociados na BM&FBovespa, a bolsa de valores brasileira. Os resultados mostram que, sob certas condições, as redes produzem níveis aceitáveis de previsão e, quando utilizadas em conjunto com a análise fundamentalista, tornam-se ferramenta poderosa para a tomada de decisão do investidor.

Palavras-Chave: Redes Neurais Artificiais; Mercado Acionário; Regularização Bayesiana; Predição; Aprendizado de Máquina.

SUMÁRIO

1	Introdução	13
1.1	Motivação	14
1.2	Justificativa	14
1.3	Objetivos	15
1.4	Estrutura do documento	15
2	Referencial Teórico	17
2.1	Mercado de Capitais	17
2.1.1	Ações	17
2.1.2	Tipos de Ações	18
2.1.3	Lucros e Dividendos	19
2.1.4	Direito de subscrição	19
2.1.5	Desdobramento ou <i>split</i>	20
2.1.6	Corretoras	21
2.1.7	Bolsa de Valores	21
2.1.7.1	BM&FBovespa	22
2.1.8	<i>Home Broker</i>	23
2.2	Redes Neurais Artificiais	23
2.2.1	Definição	24
2.2.2	O cérebro humano	25
2.2.3	Modelos de Neurônio	26
2.2.4	Arquiteturas de Rede	27
2.2.4.1	Redes Alimentadas Adiante com Camada Única	27
2.2.4.2	Redes Alimentadas Diretamente com Múltiplas Camadas	28
2.2.4.3	Redes Recorrentes	29
2.2.5	Processos de Aprendizagem	30
2.2.6	Perceptrons	31

2.2.6.1	Algoritmo de Retropropagação	32
2.2.7	Aplicações	32
2.2.8	Avaliação de desempenho	33
2.2.9	Regularização <i>Bayesiana</i>	34
2.3	Predição e mercado acionário	35
2.3.1	Análise Fundamentalista	36
2.3.2	Análise Técnica	37
2.3.2.1	Indicadores técnicos	38
2.3.3	Trabalhos relacionados	38
3	Metodologia	41
3.1	Identificação da pesquisa	41
3.2	Definição de entradas	41
3.3	Coleta de dados	46
3.4	Cálculo dos indicadores técnicos	48
3.5	Escolha do ambiente de desenvolvimento	48
3.6	Preparação dos dados	50
3.7	Modelagem da RNA	52
3.8	Treinamento da RNA	54
3.9	Aplicação de métrica de desempenho	55
3.10	Testes e análise dos resultados	56
4	Resultados e Discussão	57
4.1	Aplicação da Regularização <i>Bayesiana</i>	57
4.2	Cenários de estudo	59
4.2.1	Cenário I: BBDC4 no período de 03/01/2011 a 30/09/2013	59
4.2.2	Cenário II: ITUB4 no período de 03/01/2011 a 30/09/2013	62
4.2.3	Cenário III: OGXP3 no período de 01/02/2010 a 25/10/2012	63
4.2.4	Cenário IV: PETR4 no período de 03/01/2011 a 30/09/2013	68

4.2.5	Cenário V: VALE5 no período de 03/01/2011 a 30/09/2013	69
4.3	Discussão dos cenários	72
4.3.1	Previsões destoantes	75
4.3.2	Erros médios	77
5	Conclusões	79

LISTA DE FIGURAS

2.1	Neurônio humano. Fonte: (BARRETO, 2002).	25
2.2	Modelo não-linear de um neurônio. Fonte: (HAYKIN, 2007)	26
2.3	Rede alimentada adiante com camada única. Fonte: (HAYKIN, 2007)	28
2.4	Rede alimentada adiante totalmente conectada com uma camada oculta e outra de saída. Fonte: HAYKIN, 2007	29
2.5	Rede recorrente sem auto-realimentação e sem neurônios ocultos. Fonte: (HAYKIN, 2007)	30
2.6	Exemplo de análise técnica para avaliação de tendências. Fonte: www.advfn.com	37
2.7	Exemplo de identificação de “triângulos” (padrões gráficos) em séries históricas. Fonte: www.investmax.com.br	39
3.1	Exemplo de médias móveis exponenciais de 10, 12 e 26 dias do papel Petrobras PN (PETR4)	45
3.2	Exemplo de dados coletados em sua forma bruta	47
3.3	Trecho da planilha contendo o resultado do cálculo de indicadores para o papel OGXP3	49
3.4	Suporte nativo à técnica de regularização bayesiana no Matlab	50
3.5	Interface auxiliar para estruturação de redes neurais no Matlab	51
3.6	Ambiente de importação de dados no Matlab	52
3.7	Modelo de RNA: 3 camadas contendo 13 neurônios na camada de entrada, 6 neurônios na camada intermediária e 1 neurônio na ca- mada de saída	54
4.1	Histograma de erros sem regularização bayesiana	58
4.2	Histograma de erros com regularização bayesiana	58
4.3	BBDC4 - Desempenho real da série temporal em todo o intervalo	60
4.4	BBDC4 - Comparação entre o desempenho desejável e o desempenho previsto no intervalo destinado à testes	60

4.5	BBDC4 - Percentual de acurácia do intervalo destinado à testes	61
4.6	BBDC4 - Taxas de acerto de previsão para o período de treinamento e de testes	62
4.7	ITUB4 - Desempenho real da série temporal em todo o intervalo . . .	63
4.8	ITUB4 - Comparação entre o desempenho desejável e o desempenho previsto no intervalo destinado à testes	64
4.9	ITUB4 - Percentual de acurácia do intervalo destinado à testes	65
4.10	ITUB4 - Taxas de acerto de previsão para o período de treinamento e de testes	65
4.11	OGXP3 - Desempenho real da série temporal em todo o intervalo . . .	66
4.12	OGXP3 - Comparação entre o desempenho desejável e o desempenho previsto no intervalo destinado à testes	67
4.13	OGXP3 - Percentual de acurácia do intervalo destinado à testes	68
4.14	OGXP3 - Taxas de acerto de previsão para o período de treinamento e de testes	68
4.15	PETR4 - Desempenho real da série temporal em todo o intervalo . . .	70
4.16	PETR4 - Comparação entre o desempenho desejável e o desempenho previsto no intervalo destinado à testes	70
4.17	PETR4 - Percentual de acurácia do intervalo destinado à testes	71
4.18	PETR4 - Taxas de acerto de previsão para o período de treinamento e de testes	72
4.19	VALE5 - Desempenho real da série temporal em todo o intervalo . . .	73
4.20	VALE5 - Comparação entre o desempenho desejável e o desempenho previsto no intervalo destinado à testes	73
4.21	VALE5 - Percentual de acurácia do intervalo destinado à testes	74
4.22	VALE5 - Taxas de acerto de previsão para o período de treinamento e de testes	75
4.23	OGXP3 - Momento de forte queda não-previsto pela rede	76

LISTA DE TABELAS

3.1	OGXP3 - Definição do número de neurônios na camada oculta	53
3.2	VALE5 - Definição do número de neurônios na camada oculta	53
3.3	VALE5 - Definição de período de dados	55
4.1	Comparação Regularização Bayesiana x Levenberg-Marquardt sem regularização	57
4.2	BBDC4 - Trecho da tabela com resultados das previsões no intervalo destinado à testes	61
4.3	BBDC4 - Percentual de acurácia do intervalo destinado à testes	61
4.4	ITUB4 - Trecho da tabela com resultados das previsões no intervalo destinado à testes	64
4.5	ITUB4 - Percentual de acurácia do intervalo destinado à testes	64
4.6	OGXP3 - Trecho da tabela com resultados das previsões no intervalo destinado à testes	67
4.7	OGXP3 - Percentual de acurácia do intervalo destinado à testes	67
4.8	PETR4 - Trecho da Tabela com resultados das previsões no intervalo destinado à testes	71
4.9	PETR4 - Percentual de acurácia do intervalo destinado à testes	71
4.10	VALE5 - Trecho da tabela com resultados das previsões no intervalo destinado à testes	74
4.11	VALE5 - Percentual de acurácia do intervalo destinado à testes	74
4.12	Erros médios entre cenários	77

1 INTRODUÇÃO

Prever comportamentos futuros no mercado acionário é um desafio recorrente da comunidade científica internacional. Ao longo das últimas duas décadas, o uso de diferentes técnicas de aprendizado de máquina e inteligência computacional têm apresentado evoluções consideráveis para destrinchar a complexidade do problema. As séries temporais de preços são caracterizadas pela não-linearidade, descontinuidades e grande quantidade de variáveis que influenciam as flutuações. Fatores externos como notícias acerca das empresas, fatores políticos e econômicos, bem como aspectos emocionais dos investidores, também influenciam nas cotações.

Pesquisas recentes mostram que o uso de redes neurais artificiais (RNAs) para previsão de cotações futuras vêm apresentando resultados satisfatórios quando comparados com outras técnicas de aprendizado de máquina. A facilidade de incorporar uma grande quantidade de parâmetros e a capacidade de fazer generalizações em séries temporais com relacionamentos não-lineares são os grandes diferenciais das RNAs.

Por outro lado, a regularização bayesiana é um método aplicado na fase de treinamento de RNAs que visa minimizar problemas de convergência, ajustando as redes e aprimorando a capacidade de generalização. Recentemente, Ticknor (2013) demonstrou aplicações da técnica na área de pesquisa em questão. Dessa forma, minimizou-se problemas de super-ajuste (*overfitting*) e sub-ajuste (*underfitting*) da rede aos dados de treinamento, aumentando a qualidade das generalizações.

O presente trabalho apresenta um estudo da aplicação de RNAs para previsão de preços futuros dos mais relevantes papéis da BM&FBovespa, a bolsa de valores brasileira.

1.1 Motivação

Quanto mais desenvolvido é o mercado de capitais, maior é a economia de um país. Investir no mercado de ações é uma opção que investidores têm capaz de formar patrimônio para o futuro e, ao mesmo tempo, fornecer recursos para o crescimento das empresas. Com mais recursos, as empresas podem aumentar sua produção, gerar empregos e colaborar para o progresso do país.

Aplicar uma técnica científica de inteligência computacional em um mercado tão importante, participando de um ciclo econômico de impacto mundial e estimular novos investidores a entrarem no mercado e fortalecerem a bolsa de valores brasileira é o desafio e a motivação de execução do presente trabalho. O trabalho também serve de motivação para outros pesquisadores desenvolverem técnicas e abordagens diferenciadas na predição aplicada ao mercado acionário.

1.2 Justificativa

Grandes organizações, principalmente nos países desenvolvidos, têm, dentre sua carteira de investimentos, ativos de renda variável. O estudo desta área pode trazer resultados que gerem novas informações acerca do comportamento do mercado e, consequentemente, potencializar eventuais ganhos.

É interessante também destacar que negociações no mercado acionário possuem impacto além da esfera financeira. O impacto a longo prazo ocorre em todo o setor real da economia. De acordo com BMFBovespa (2011), estudos divulgados pelo Banco Mundial encontraram alto grau de correlação entre os indicadores dos mercados acionários e o crescimento econômico médio mundial entre 1976 e 1996: “... a conclusão foi de que o mercado acionário não apenas seguiu o crescimento econômico, mas proporcionou os meios para prognosticar as taxas futuras de crescimento do capital, da produtividade e da renda per capita” (BMF-BOVESPA, 2011).

Para as organizações de capital aberto, o mercado de ações inflado também é interessante, uma vez que utilizam rotineiramente o mercado para levantamento de capital e geração de dividendos para os acionistas. Investimentos através do mercado acionário geram novos empregos e a expansão do setor privado. Dessa forma, possibilita-se a reorientação dos recursos do setor público para as camadas e setores menos favorecidos.

1.3 Objetivos

O presente trabalho tem como objetivo geral modelar e treinar uma RNA para predição futura do valor de fechamento do próximo dia dos mais relevantes papéis da BM&F Bovespa S.A. Como objetivos específicos pode-se considerar:

- minimizar problemas na fase de treinamento da RNA através da técnica de regularização *bayesiana* visando aprimorar a capacidade de generalização da rede;
- identificar em quais condições e para quais tipos de situações a RNA apresenta melhores resultados;
- analisar a acurácia das predições através de uma métrica de desempenho.

1.4 Estrutura do documento

Este documento está organizado em seis capítulos: introdução, referencial teórico, metodologia, resultados e discussão, conclusões e referências bibliográficas.

O presente capítulo contextualiza e introduz o assunto a ser tratado, bem como define os objetivos a serem alcançados. O Capítulo 2 apresenta o referencial teórico, os conceitos importantes para o entendimento do trabalho. Também são demonstradas as contribuições científicas correlatas sobre o assunto. O Capítulo 3 apresenta o conjunto de métodos, técnicas e procedimentos que tem por finalidade

viabilizar a execução da pesquisa e gerar conhecimento. Já o Capítulo 4 busca listar e detalhar efeitos e consequências decorrentes da execução da metodologia de pesquisa proposta. O Capítulo 5 apresenta as conclusões, contribuições finais do trabalho e sugestões de trabalhos futuros. Por fim, apresenta-se as referências bibliográficas que embasaram a pesquisa.

2 REFERENCIAL TEÓRICO

Este capítulo apresenta os conceitos básicos para entendimento do presente trabalho, bem como são demonstradas algumas contribuições científicas correlatas sobre o assunto.

2.1 Mercado de Capitais

O mercado de capitais é um sistema de distribuição de valores mobiliários que visa proporcionar liquidez aos títulos de emissão de empresas e viabilizar seu processo de capitalização. É constituído pelas bolsas, corretoras e outras instituições financeiras autorizadas. (BMFBOVESPA, 2010)

No mercado de capitais, os principais títulos negociados são as ações e debêntures. As ações representam o capital das empresas, enquanto os debêntures dizem respeito à empréstimos tomados no mercado.

2.1.1 Ações

Ações são títulos de renda variável, emitidos por sociedades anônimas, que representam a menor fração do capital da empresa emissora. Podem ser escriturais ou representadas por cautelas ou certificados (nominativas). O investidor de ações é um coproprietário da sociedade anônima da qual é acionista, participando dos seus resultados. As ações são conversíveis em dinheiro, a qualquer tempo, pela negociação em bolsa ou no mercado de balcão. (BMFBOVESPA, 2010)

Emitir ações é uma das maneiras que as empresas têm de captar recursos no mercado. Se uma empresa pretende expandir seus negócios ou realizar investimentos e não possui recursos para tal, ela pode alavancar capital a partir da emissão de novas ações que são disponibilizadas no mercado através da bolsa de valores.

O investidor de ações contribui para a produção de bens dos quais também é consumidor. Como acionista, ele é sócio da empresa e se beneficia da distribuição de dividendos sempre que a empresa obtiver lucros. (BMFBOVESPA, 2010)

Em geral, os acionistas participam do lucro da companhia por meio do recebimento de dividendos e de bonificações. Quando for o caso de emissão de novas ações por parte da companhia, haverá ainda o direito de subscrição dessas ações. Os acionistas podem ganhar também com a possível valorização do preço das ações no mercado. Entretanto, não há garantia de valorização. Ao contrário, o preço pode cair, ou até mesmo, em casos extremos, perder totalmente seu valor. Esse resultado dependerá fundamentalmente da gestão da companhia e das condições gerais da economia. Portanto, o investimento em ações é considerado como de renda variável e está sempre sujeito ao risco de mercado inerente aos negócios empresariais e à economia. (CVM, 2013)

2.1.2 Tipos de Ações

As ações são classificadas de acordo com seu tipo, caracterizando-se como ações ordinárias ou preferenciais. A classificação difere conforme os direitos que concedem a seus acionistas.

As ações ordinárias (ON) são as que proporcionam participação nos resultados econômicos de uma empresa, conferindo a seu titular o direito de voto em assembleia.

As ações do tipo preferencial (PN) são as que oferecem a seu detentor prioridade no recebimento de dividendos e/ou, no caso de dissolução da empresa, prioridade no reembolso de capital. Em geral, não concedem direito a voto em assembleia.

As ações preferenciais também podem ser diferenciadas por classes, como A, B, C ou alguma outra letra que apareça após o PN. Cada empresa estabelece características especiais para cada tipo de classe, portanto, é impossível fazer uma

definição geral de cada classe. Para saber as características de uma determinada classe de ação, é necessário consultar o estatuto social da empresa em questão.

2.1.3 Lucros e Dividendos

No exercício de suas atividades, as companhias auferem receita. É o que acontece, por exemplo, quando a sociedade presta serviços ou vende produtos, recebendo em contrapartida o valor correspondente. Ao longo de um ano, ou exercício social, estas receitas vão se acumulando e, ao final do período, a companhia deve verificar qual o total das receitas auferidas e diminuir-las do total das despesas incorridas e outros ajustes impostos pela legislação societária e fiscal, obtendo o denominado “resultado do exercício” (CVM, 2013).

Ao final de cada exercício, os administradores devem ouvir o Conselho Fiscal (se estiver em funcionamento) e posteriormente submeter à Assembleia Geral Ordinária da companhia as demonstrações financeiras relativas ao período encerrado. Juntamente com tais demonstrações financeiras, os administradores devem apresentar uma proposta de destinação do lucro líquido daquele exercício, se algum lucro tiver sido auferido, isto é, quais parcelas serão utilizadas para a constituição de reservas, retenção de lucros e distribuição de dividendos (CVM, 2013).

Dividendo é a parcela do lucro líquido que, após a aprovação da Assembleia Geral Ordinária, será destinada aos acionistas da companhia. O montante dos dividendos deverá ser dividido entre as ações existentes, para se apurar quanto será devido aos acionistas por cada ação por eles detida.

2.1.4 Direito de subscrição

Quando uma empresa resolve aumentar seu capital social colocando mais ações em circulação através de uma oferta pública de ações, os atuais acionistas têm prioridade para subscreverem (adquirirem) essas novas ações na proporção das

ações que já possuem, por preço e prazo pré-determinados. Isso garante o direito à manutenção de suas posições acionárias (INVESTPEDIA, 2009).

Como o preço é pré-determinado, isso pode gerar uma vantagem para o acionista, caso as ações da companhia em questão apresentem preços maiores no mercado. Caso o acionista não queira efetuar a aquisição de tais ações, ele pode vender esse direito no mercado. Como até o vencimento do direito de subscrição o valor das cotações pode variar muito, a compra e venda desses direitos pode gerar uma onda especulativa por parte dos investidores, devido à expectativa de tais direitos poderem ou não gerar uma vantagem a quem os detiver (INVESTPEDIA, 2009).

2.1.5 Desdobramento ou *split*

O desdobramento ou *split* é uma estratégia utilizada pelas empresas com o principal objetivo de melhorar a liquidez de suas ações. Acontece quando as cotações estão muito elevadas, o que dificulta a entrada de novos investidores no mercado.

Para exemplificar, considerando que uma ação é cotada ao valor de R\$150,00, com lote padrão de 100 ações. Para comprar um lote dessas ações o investidor teria que desembolsar R\$15.000,00, que é uma quantia considerável para a maior parte dos investidores pessoa física. Desdobrando suas ações na razão de 1 para 3, cada ação dessa empresa seria multiplicada por 3. Assim, quem possuísse 100 ações, passaria a possuir 300 ações. O valor da cotação seria dividido por 3, ou seja, passaria de R\$150,00 para R\$50,00.

Na prática, o desdobramento de ações não altera de forma alguma o valor do investimento ou o valor da empresa, é apenas uma operação de multiplicação de ações e divisão dos preços para aumentar a liquidez das ações.

2.1.6 Corretoras

Segundo **BMFBovespa (2010)**, corretoras são instituições financeiras credenciadas pelo Banco Central do Brasil, pela Comissão de Valores Mobiliários e pela Bolsa, habilitadas a negociar valores mobiliários em pregão. As corretoras podem ser definidas como intermediárias especializadas na execução de ordens e operações por conta própria e determinadas por seus clientes, além da prestação de uma série de serviços a investidores e empresas, tais como:

- diretrizes para seleção de investimentos;
- intermediação de operações de câmbio;
- assessoria a empresas na abertura de capital, emissão de debêntures e debêntures conversíveis em ações, renovação do registro de capital, etc.

2.1.7 Bolsa de Valores

As bolsas de valores são instituições que administram mercados. Elas são centros de negociação de valores mobiliários, que utilizam sistemas eletrônicos de negociação para efetuar compras e vendas desses valores, que podem ser ações de companhia abertas (públicas ou privadas), contratos futuros, derivativos, etc.

De acordo com **CVM (2013)**, a principal função dos mercados de bolsa e de balcão é organizar, manter, controlar e garantir ambientes ou sistemas propícios para o encontro de ofertas e a realização de negócios com formação eficiente de preços, transparência e divulgação de informações e segurança na compensação e liquidação dos negócios. Assumindo essas funções, são inúmeros os benefícios gerados pelas bolsas de valores para a economia e a sociedade, entre os quais cabe destacar:

- financiamento para a capitalização das empresas através da venda de ações;

- estímulo à aplicação de poupanças em ações de companhias, com benefícios para os diferentes setores da economia;
- facilidade nos processos de fusões e aquisições de companhias;
- estímulo à redução da desigualdade na distribuição de renda da sociedade;
- aprimoramento da governança corporativa, com significativas melhoras nos padrões de administração e eficiência das empresas;
- abertura de oportunidades de participação no mercado de ações para pequenos e médios investidores;
- atuação como termômetro da economia do país;
- veículo eficaz para o financiamento das iniciativas públicas de desenvolvimento, pela capacidade de colocação de títulos públicos.

2.1.7.1 BM&FBovespa

A BM&FBOVESPA, a única bolsa de valores brasileira com sede em São Paulo, oferece negociação de ações, contratos futuros, de opções, a termo e de *swaps* referenciados em índices, taxas de juro e câmbio, e *commodities* agropecuárias e de energia, além de operações no mercado a vista, como ouro, dólar e títulos públicos federais.

A Bolsa de Valores, Mercadorias e Futuros (BM&FBOVESPA) foi criada em maio de 2008 com a integração da Bolsa de Mercadorias & Futuros e da Bovespa Holding. Juntas, essas companhias originaram uma das maiores bolsas do mundo em valor de mercado (BMFBOVESPA, 2010).

A principal função da BM&FBOVESPA é proporcionar um ambiente transparente e líquido, adequado à realização de negócios com valores mobiliários. Somente através das corretoras, os investidores têm acesso aos sistemas de negociação para efetuarem suas transações de compra e venda de valores.

2.1.8 *Home Broker*

O *home broker* é uma ferramenta de acesso aos mercados da Bolsa oferecida por quase todas as corretoras e por meio da qual os investidores negociam ações, derivativos, minicontratos e/ou fundos negociados através da Internet, enviando as ordens de compra e venda pelo *site* da corretora (CVM, 2013).

As funcionalidades básicas dos sistemas de *home broker* são a colocação de ordens de compra e venda, a verificação de posição acionária e de execução das ordens e o acesso às cotações dos ativos negociados.

O *home broker*, com auxílio da evolução das tecnologias de informação, facilita e agiliza as opções de acesso à bolsa. De acordo com CVM (2013), as maiores vantagens em se utilizar o *home broker* são:

- acesso às cotações dos ativos;
- acompanhamento da posição da carteira, de ordens e financeira;
- programação e envio de ordens e recebimento de confirmações de aceitação, de execução ou de cancelamento;
- resumo financeiro das operações executadas e suas respectivas notas de corretagens;
- acompanhamento e realização de operações a partir de qualquer local com acesso à Internet, inclusive de dispositivos móveis, oferecendo agilidade aos investidores.

2.2 Redes Neurais Artificiais

O trabalho em redes neurais artificiais tem sido motivado desde o começo pelo reconhecimento de que o cérebro humano processa informações de uma forma

inteiramente diferente do computador digital convencional. O cérebro é um computador altamente complexo, não linear e paralelo. Ele tem a capacidade de organizar os neurônios, de forma a realizar certos processamentos, para reconhecer padrões, percepção, e controle motor muito mais rapidamente que o mais rápido computador digital hoje existente (HAYKIN, 2007).

As redes neurais artificiais (RNAs) foram desenvolvidas com intuito de simular matematicamente o comportamento de um neurônio biológico. Sua forma de conhecimento é representada em forma de aprendizagem através da experiência. Constituindo uma das áreas da inteligência artificial, as RNAs são normalmente utilizadas nos problemas em que é necessário algum tipo de aprendizagem (HAYKIN, 2007).

Numa rede neural não se tem a idéia de programa, onde o programador introduz e codifica a estratégia de solução do problema. Também não se tem a idéia de um conhecimento explicitamente armazenado que conduza a busca durante o processo de resolução do problema. A rede neural é dinâmica, não possui memória, não acessa nem possui arquivos de dados e não é programável (THOMÉ, 2002).

2.2.1 Definição

Haykin (2007) afirma que rede neural é um processador paralelamente distribuído, constituído de unidades de processamento simples, que têm a propensão natural para armazenar conhecimento experimental e torná-lo disponível para uso. Ela assemelha-se ao cérebro em dois aspectos:

1. o conhecimento é adquirido pela rede a partir de seu ambiente através de um processo de aprendizagem;
2. forças de conexão entre neurônios.

2.2.2 O cérebro humano

RNAs buscam simular a forma de aprendizado por experiência do cérebro humano através dos neurônios e suas complexas ligações.

O neurônio tem um corpo celular chamado soma e diversas ramificações. As ramificações conhecidas como dendritos, conduzem sinais das extremidades para o corpo celular. Existe também uma ramificação, geralmente única, chamada axônio, que transmite um sinal do corpo celular para suas extremidades. As extremidades do axônio são conectadas com dendritos de outros neurônios pelas sinapses (BARRETO, 2002). A Figura 2.1 apresenta o neurônio humano.




Figura 2.1: Neurônio humano. Fonte: (BARRETO, 2002).

Cada vez que uma sinapse é ativada ou consegue ativar outro neurônio, o número de neurotransmissores liberados aumenta na próxima vez que o neurônio for ativado, representando assim um aumento de conexão entre os dois neurônios (BARRETO, 2002).

2.2.3 Modelos de Neurônio

A construção de RNAs tem inspiração nos neurônios biológicos e nos sistemas nervosos. Os modelos neurais foram concebidos com base na estrutura do sistema nervoso, mais especificamente na estrutura do cérebro humano e, assim, sua principal característica está na capacidade de aprender com base na exposição a exemplos. A construção de uma rede neural se constitui, portanto, na configuração da sua arquitetura interna (uma rede interligada de neurônios) e no treinamento desta rede com base em exemplos, até que ela própria consiga aprender como resolver o problema (THOMÉ, 2002). A Figura 2.2 apresenta o modelo não-linear de um neurônio.

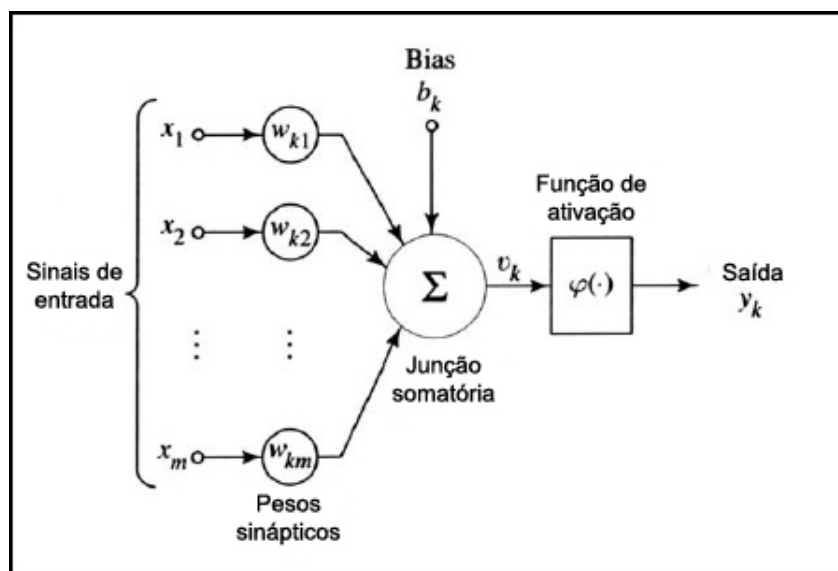


Figura 2.2: Modelo não-linear de um neurônio. Fonte: (HAYKIN, 2007)

De acordo com Haykin (2007), são três os elementos básicos do modelo neuronal:

1. um conjunto de sinapses ou elos de conexão, cada uma caracterizada por um peso ou força própria;

2. um somador para somar os sinais de entrada, ponderado pelas respectivas sinapses do neurônio;
3. uma função de ativação para restringir a amplitude de saída de um neurônio.

A função de ativação é referida também como função restritiva já que restringe o intervalo permissível de amplitude do sinal de saída a um valor finito. Tipicamente, o intervalo normalizado da amplitude da saída de um neurônio é escrito como intervalo unitário fechado $[0,1]$ ou alternativamente $[-1,1]$.

2.2.4 Arquiteturas de Rede

As disposições estruturais de uma rede neural podem ser concebidas de diversas formas conforme as necessidades da aplicação e em conformidade com o algoritmo de aprendizagem usado para treinar a rede. Segundo Haykin (2007), os itens que formam a estrutura de uma rede neural são as camadas intermediárias (ocultas), a quantidade de neurônios, a função de transferência ou ativação e o algoritmo de aprendizado.

Existem três classes de arquiteturas de redes fundamentalmente diferentes: redes alimentadas adiante com camada única, redes alimentadas diretamente com múltiplas camadas e redes recorrentes.

2.2.4.1 Redes Alimentadas Adiante com Camada Única

A designação “camada única” se refere à camada de saída de nós computacionais (neurônios). A camada de entrada de nós da fonte não é considerada por não ser realizada qualquer computação (HAYKIN, 2007).

Estas redes também são definidas como redes diretas, ou chamadas também de *feedforward*, cujos grafos não têm ciclos. Como observável na Figura 2.3, nestas redes, os neurônios que recebem sinais de excitação são chamados de camada de entrada, ou primeira camada. Neurônios que têm sua saída, como saída da rede, pertencem a camada de saída ou última camada (BARRETO, 2002).




Figura 2.3: Rede alimentada adiante com camada única. Fonte: (HAYKIN, 2007)

2.2.4.2 Redes Alimentadas Diretamente com Múltiplas Camadas

Neurônios que não pertencem nem a camada de entrada nem a de saída são neurônios internos à rede, podendo se organizar em uma ou mais camadas internas, chamadas de camadas ocultas (*hidden layers*). A função dos neurônios ocultos é intervir entre a entrada externa e a saída da rede de uma maneira útil. Adicionando-se uma ou mais camadas ocultas, a rede torna-se capaz de extrair estatísticas de ordem elevada (HAYKIN, 2007).

Estas redes são as mais populares, principalmente por existirem métodos de aprendizado bastante difundidos e fáceis de usar. São capazes também de aproximar, com maior ou menor precisão, dependendo do número de neurônios da rede, qualquer função não-linear (BARRETO, 2002).

A rede neural apresentada na Figura 2.4 é dita totalmente conectada, no sentido de que cada um dos nós de uma camada de rede está conectado a todos os nós da camada adjacente seguinte. Entretanto, se alguns dos elos de comunicação (conexões sinápticas) estiverem faltando na rede, dizemos que a rede é parcialmente conectada (HAYKIN, 2007).




Figura 2.4: Rede alimentada adiante totalmente conectada com uma camada oculta e outra de saída.
Fonte: HAYKIN, 2007

2.2.4.3 Redes Recorrentes

Uma rede neural recorrente se distingue de uma rede neural alimentada adiante por ter pelo menos um laço de realimentação. Redes recorrentes são aquelas que, além de apresentarem ciclos, envolvem neurônios dinâmicos. Os ciclos podem ser, ou com realimentação, ou com retroação, ou com *feedback* (HAYKIN, 2007).

Na estrutura representada na Figura 2.5, não há laços de auto-realimentação na rede, isto é, uma situação onde a saída de um neurônio é realimentada para a sua própria entrada. A Figura 2.5 também não tem neurônios ocultos.

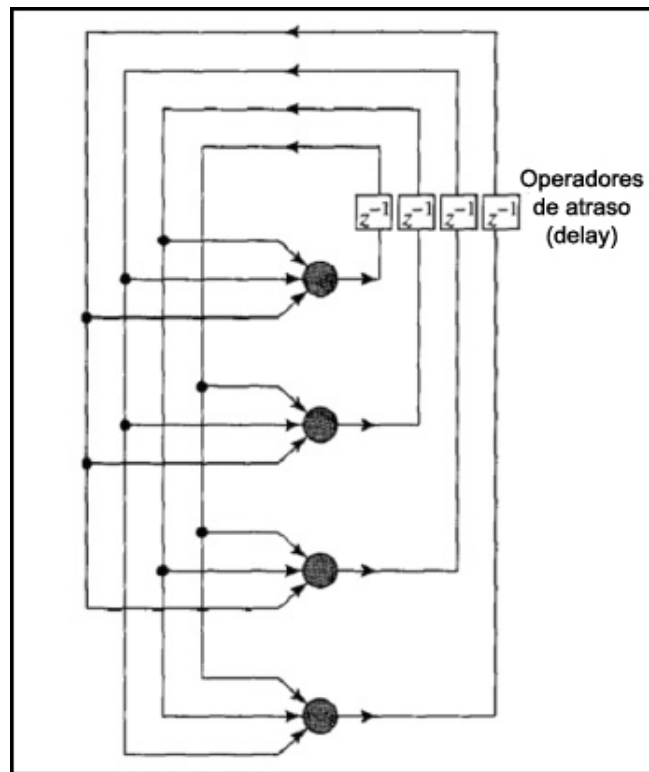


Figura 2.5: Rede recorrente sem auto-realimentação e sem neurônios ocultos. Fonte: (HAYKIN, 2007)

2.2.5 Processos de Aprendizagem

Aprender é o ato que produz um comportamento diferente a um estímulo externo devido à excitações recebidas no passado e é, de uma certa forma, sinônimo de aquisição de conhecimento. Dessa forma, segundo Haykin (2007), é possível montar a seguinte sequência de eventos:

1. a rede neural é estimulada por um ambiente;

2. a rede neural sofre modificações nos seus parâmetros livres como resultado desta estimulação;
3. a rede neural responde de uma maneira nova ao ambiente, devido às modificações ocorridas na sua estrutura interna.

Basicamente, as redes neurais obedecem a dois paradigmas fundamentais de aprendizado: aprendizado supervisionado e aprendizado não-supervisionado.

No aprendizado supervisionado, também chamado de aprendizado com professor, conjunto de exemplos de entrada-saída são apresentados à rede. A partir do valor de entrada, a rede realiza seu processamento e a saída obtida é comparada com a saída esperada. Caso não sejam iguais, um processo de ajuste de pesos é aplicado buscando-se um erro mínimo ou aceitável. Segundo McClelland *et al.* (1986), o algoritmo de aprendizado supervisionado para redes neurais mais conhecido e utilizado é o *backpropagation*.

Já o aprendizado não-supervisionado é caracterizado pela ausência de algum elemento externo supervisor, ou seja, um padrão de entrada fornecido permite que a rede livremente escolha o padrão de saída a partir das regras de aprendizado adotadas. É segmentado em aprendizado por reforço, que consiste no mapeamento entrada-saída através da interação com o ambiente, e na aprendizagem não-supervisionada ou auto-organizada onde, a partir de métricas de qualidade do aprendizado ocorre a otimização dos parâmetros livres da rede. Segundo Haykin (2007), os algoritmos de aprendizado não supervisionados mais importantes são o Algoritmo de Hopfield e Mapas de Kohonen.

2.2.6 Perceptrons

O perceptron é a forma mais simples de uma rede neural usada para a classificação de padrões ditos linearmente separáveis. Basicamente, ele consiste de um único neurônio com pesos sinápticos ajustáveis. Foi proposto por Rosenblatt em 1958, como primeiro modelo para aprendizagem com um professor (HAYKIN, 2007).

Perceptrons de múltiplas camadas (MLP, Multilayer Perceptron) são redes neurais compostas por um conjunto de unidades sensoriais que constituem a camada de entrada, uma ou mais camadas ocultas e uma camada de saída. O sinal de entrada se propaga para frente através da rede, camada por camada (HAYKIN, 2007).

2.2.6.1 Algoritmo de Retropropagação

Muito utilizado em modelos de predição, a retropropagação (*backpropagation*) é uma regra de aprendizado supervisionado. Criada em 1987, é a mais popular regra de aprendizado. No contexto de redes neurais, para seu funcionamento, apresenta-se à rede um exemplo e verifica-se a saída da rede, saída esta que é comparada à saída esperada gerando um erro. A técnica baseia-se em dois passos através de diferentes camadas de rede: um passo para frente, a propagação, e um passo para trás, a retropropagação. No passo para frente, um vetor de entrada é aplicado aos nós sensoriais da rede e seu efeito se propaga através dela, camada por camada. Um conjunto de saída então é produzido como a resposta real da rede. Durante a propagação, os pesos sinápticos da rede são todos fixos. Por outro lado, durante o passo de retropropagação, os pesos sinápticos são todos ajustados de acordo com a regra de correção de erro. A resposta real da rede é subtraída da resposta desejada para produzir um sinal de erro. Este sinal é então propagado para trás através da rede, contra a direção das conexões sinápticas. Os pesos reais novamente são ajustados para que a resposta real da rede se mova para mais perto da resposta desejada (HAYKIN, 2007).

2.2.7 Aplicações

As RNAs representam uma tecnologia que possui raízes em muitas disciplinas, como a neurociência, matemática, estatística, física, engenharia, e a ciência da computação. Entre os campos de suas aplicações encontram-se o reconhecimento

de padrões, análise de séries temporais, processamento de sinais e controle, em virtude de sua propriedade de aprender a partir de dados de entrada com ou sem a necessidade de um professor (HAYKIN, 2007).

Através da classificação de dados e reconhecimento de padrões, verifica-se também aplicações diversas em termos de análise de imagem, voz, aroma e odor. Outras aplicações práticas consideráveis são o reconhecimento ótico de caracteres (OCR), diagnósticos médicos automatizados, radares de trânsito inteligentes e detecção automática de fraudes em cartões em créditos.

2.2.8 Avaliação de desempenho

Para avaliar o poder de convergência de uma RNA, ou seja, a capacidade da rede de aprender e identificar padrões, o desempenho deve ser mensurado. Para tal, durante a fase de treinamento, recomenda-se calcular o erro quadrático médio, mais comumente conhecido como MSE (Mean Squared Error). O MSE é calculado pela equação:

$$MSE = \frac{\sum_{t=1}^n (alvo_t - saida_t)^2}{n} \quad (2.1)$$

Onde:

- n = número de padrões apresentados
- $alvo$ = valor de objetivo
- $saida$ = valor de saída da rede

O MSE é uma forma de avaliar a diferença entre um estimador e o verdadeiro valor da quantidade estimada. Baseia-se no valor médio do quadrado do erro no intervalo de padrões apresentados.

2.2.9 Regularização *Bayesiana*

Durante o treinamento de uma rede neural, o objetivo principal é gerar um rede que produza um baixo erro de aprendizado e, principalmente, que seja capaz de responder adequadamente à apresentação de novos dados, isto é, que a rede tenha uma boa capacidade de generalização.

Um método considerado eficiente para aperfeiçoar a generalização de uma rede é a regularização, que se baseia na restrição dos valores dos pesos da rede buscando minimizar a função de desempenho. A idéia é manter os pesos com valores pequenos, possibilitando uma suavização da saída da rede.

A regularização *bayesiana*, com o objetivo de evitar o *overfitting* (treino em excesso gerando memorização) e melhorar a capacidade de generalização da RNA, acrescenta, ao processo de otimização, um componente que penaliza a função com o aumento do número de coeficientes, o que permite que o número de neurônios da camada escondida seja redefinido automaticamente durante o processo de treinamento.

Segundo Araújo e Gama (2004), a regularização *bayesiana*, consiste em uma técnica de treinamento que adiciona um termo de penalização (regularização) à função objetivo, de forma que o algoritmo de estimação faça com que parâmetros irrelevantes converjam para zero, reduzindo assim o número de parâmetros efetivos utilizados no processo (procedimento conhecido como “poda”).

Na regularização *bayesiana*, proposta por MacKay (1992), modifica-se a função de custo F que é normalmente usada, o erro quadrático médio (E_d).

$$F = E_d = \frac{1}{n} \sum_{i=1}^n (e_i)^2 \quad (2.2)$$

A função objetivo na Equação 2.2 é expandida com a adição do termo E_w que é a soma dos quadrados dos pesos e *bias*.

$$F = \beta E_d + \alpha E_w \quad (2.3)$$

Onde α e β são os parâmetros de regularização e E_w é dada por:

$$E_w = \frac{1}{n} \sum_{j=0}^n (w_j)^2 \quad (2.4)$$

A utilização desta nova função de custo faz com que a rede tenha pesos e *bias* com valores menores, gerando uma resposta mais suave, o que diminui a possibilidade de supertreinamento. É bastante desejável que se obtenha os parâmetros de regularização ótimos de forma automática. Isto pode ser feito seguindo o que foi proposto por MacKay (1992) que considera os pesos e *bias* variáveis aleatórias com distribuições especificadas. Os parâmetros de regularização estão relacionados com as variâncias desconhecidas destas distribuições. Sendo assim, é possível estimar estes parâmetros através de técnicas estatísticas.

2.3 Predição e mercado acionário

Mercados de ações fortes são considerados verdadeiros motores propulsores do desenvolvimento econômico. Prospectar o comportamento futuro das ações é um interesse comum a investidores de todos os portes.

Sendo assim, os estudos em predição de ações são divididos basicamente em três vertentes. Existem os que não acreditam que investidores possam conseguir vantagens consideráveis em suas transações, fundamentando-se fortemente em teorias de aleatoriedade no mercado. Há também aqueles que consideram mais relevantes aspectos relacionados à análise fundamentalista das empresas e indicadores macro-econômicos. Por fim, destaca-se a vertente que considera que a partir das séries de dados recentes e históricos, além de indicadores técnicos, é possível conseguir generalizações aceitáveis. Os trabalhos em inteligência computacional,

especificados no presente trabalho pela técnica de redes neurais artificiais, são originários desta última abordagem.

2.3.1 Análise Fundamentalista

O bom investidor busca sempre aplicar seu dinheiro em empresas que ofereçam bons retornos dentro do prazo a ser considerado. Tratando-se de análise de opções e critérios para compra de ações, segundo Fortuna (2008), a escola fundamentalista baseia-se no resultados setoriais e específicos de cada empresa, dentro do contexto da economia nacional e internacional.

Para iniciar um investimento no mercado de ações com maior segurança, faz-se necessário analisar os indicadores de balanço e os indicadores de mercado, buscando-se antever os momentos de alta e de baixa de uma determinada ação (DECHATRE; MAJER, 2006).

A análise fundamentalista busca, basicamente, avaliar a saúde financeira das empresas, projetar seus resultados futuros e determinar o preço justo para as suas ações. Para isso, os analistas levam em consideração os chamados fundamentos da empresa, isto é, todos os fatores macro e microeconômicos que influenciam no seu desempenho.

Assim, de um lado, o analista avalia fatores como inflação, taxas de juros, câmbio, produto interno bruto (PIB), finanças públicas e decisões governamentais. De outro, olha para as características do setor em que a empresa atua, seus concorrentes e para os resultados da empresa, como balanços, dividendos, lucro e governança corporativa. A análise da empresa leva em conta, portanto, tanto o lado quantitativo - seus números - quanto o qualitativo - seus controladores, executivos, a composição do conselho administrativo e assim por diante (EXAME, 2010).

2.3.2 Análise Técnica

A análise técnica concentra seu foco exclusivamente no mercado, desconsiderando a situação financeira da empresa, seus balanços e indicadores de performance, ou, ainda, perspectivas do setor de atividade da empresa. Relaciona as oscilações de preços ao “humor” do mercado em relação à ação, e não à empresa. Acredita na repetitividade do comportamento humano e no poder da ciência estatística como forma de determinar, com base no comportamento passado, as perspectivas para o mercado no futuro (DEBASTIANI, 2008).

A análise técnica também é conhecida como escola grafista, e auxilia o investidor na escolha do melhor momento para compra e venda de ações. Esta escola “baseia-se na análise gráfica, tendo como base os volumes e os preços pelos quais foram comercializadas as ações nos pregões anteriores” (FORTUNA, 2008). A Figura 2.6 mostra um exemplo de estudo grafista para analisar a tendência de movimento de determinada ação baseada em seus resultados anteriores.



Figura 2.6: Exemplo de análise técnica para avaliação de tendências. Fonte: www.advfn.com

Através da análise técnica, pode-se selecionar a ação com maior potencial de ganho na economia. Esta escola se volta para a obtenção de vantagens através

da oscilação dos valores originados da oferta e demanda, através do estudo de gráficos que demonstram o comportamento dos preços e dos volumes, e tem uma “potencialidade marcante do ataque de tendências tanto de alta quanto de baixa do sistema, permitindo ganhos em ambas as pontas” (DESCHATRE; MAJER, 2006).

Segundo CVM (2013), a premissa básica da análise técnica é que todas as informações estão representadas nos gráficos, na medida em que se traduz o comportamento do mercado. Neste sentido, a análise técnica fundamenta-se na chamada Teoria de Dow, voltada para a interpretação dos movimentos de mercado, que afirma que “a configuração gráfica dos preços tende a se relacionar com a direção que eles tomarão no futuro”.

2.3.2.1 Indicadores técnicos

Os indicadores técnicos representam linhas de oscilação ou tendência, construídas através de formulas matemáticas ou estatísticas, cujos objetivos são antecipar, confirmar ou descrever tendências (CVM, 2013).

Indicadores representam importantes instrumentos de avaliação dos movimentos de preços em relação à tendência principal, do comportamento relativo entre compradores e vendedores, da volatilidade (intensidade e a frequência das oscilações) e liquidez (velocidade e facilidade para conversão em caixa) das ações negociadas.

2.3.3 Trabalhos relacionados

Os primeiros estudos em predição no mercado acionário com auxílio de redes neurais eram focados apenas na aplicação de RNAs e descoberta de eventual poder de predição. Kamijo e Tanigawa (1990) utilizaram redes neurais recorrentes para reconhecer padrões, mais especificamente “triângulos” nos gráficos (Figura 2.7), que, de acordo com a análise técnica considerada até então, seria um indicador de reversão de tendência de determinada ação. O estudo foi aplicado em

ações negociadas na bolsa de Tóquio. Ahmadi (1990) aplicou redes neurais com retropropagação e regra delta para tentar entender como funciona a interação entre fatores de mercado e retorno seguro. Yoon e Swales (1991) foram pioneiros em utilizar dados qualitativos e quantitativos nas redes neurais buscando aprimorar a acurácia das previsões de preços futuros de ações. Eles concluíram que, apesar de algumas limitações, era evidente que o uso de dados quantitativos e qualitativos melhoraria a tomada de decisão dos investidores, encorajando pesquisas futuras na área. Trippi e DeSieno (1992) preveram a direção diária de comportamento do S&P500, um índice composto por quinhentos ativos qualificados de acordo com suas representatividades no mercado americano. A conclusão foi que a técnica, baseada em rede neural, se utilizada em conjunto com técnicas de sistemas especialistas baseados em regras, poderia aprimorar a tomada de decisão de investidores.



Figura 2.7: Exemplo de identificação de “triângulos” (padrões gráficos) em séries históricas. Fonte: www.investmax.com.br

As redes com retropropagação praticamente ignoravam os complexos ruídos nas séries temporais. Trabalhos posteriores, como o de Lawrence, Tsoi e Giles (1998) passaram a se preocupar com este aspecto e com a constante e prejudi-

cial convergência da rede para mínimos locais. Miao, Chen e ZHAO (2007) perceberam que os problemas com redes retropropagadas poderiam ser trabalhadas observando-se o algoritmo descendente gradiente que obtém os pesos das conexões sinápticas.

Técnicas que misturavam redes neurais com outras técnicas (técnicas híbridas) começaram a surgir, sempre procurando melhorar a qualidade das previsões e buscar novos comportamentos. Tsaih, Hsu e Lai (1998) aplicaram técnicas baseadas em regras (*rule-based*), sugeridas por Trippi e DeSieno (1992), em conjunto com as redes neurais para prever a direção diária do S&P500. Resultados confirmaram que o método híbrido acrescentou melhores resultados em relação a estratégia de “compre-e-segure”, muito recomendada na época. Kohara *et al.* (1997) incorporou conhecimento prévio em suas redes, como informações econômicas quantificadas oriundas de jornais e vários indicadores macro-econômicos. Resultados mostraram que erros na previsão ficaram até 5% inferiores quando comparados com a técnica de regressão múltipla. Em linhas alternativas, Blanco, Delgado e Pegalajar (2001) buscaram prever comportamentos futuros por meio de algoritmos genéticos e Miao, Chen e ZHAO (2007) adotaram princípios de colônias bacterianas para modelar suas redes. Ambos apresentaram resultados superiores às técnicas convencionais com base somente em modelos estatísticos.

Por fim, Atsalakis e Valavanis (2009) realizaram uma pesquisa entre mais de uma centena de artigos publicados focados em previsão no mercado acionário. Os artigos utilizavam, em sua maioria, modelos de redes neurais e redes neurais associadas com lógica *fuzzy*. Os pesquisadores avaliaram os modelos em termos de dados de entrada, modelo de previsão, avaliação e medições de desempenho. Concluiu-se que as técnicas de inteligência computacional são altamente aceitáveis para o estudo e evolução do comportamento do mercado acionário.

3 METODOLOGIA

Este capítulo descreve a metodologia utilizada no trabalho para se atingir os objetivos da pesquisa. Primeiramente apresenta-se a classificação da pesquisa quanto à natureza, objetivos e forma de abordagem. Em seguida são descritos os procedimentos metodológicos da pesquisa divididos em etapas de desenvolvimento.

A pesquisa pode ser dividida em nove fases principais: definição de entradas, coleta de dados, cálculo dos indicadores técnicos, escolha do ambiente de desenvolvimento, preparação dos dados, modelagem da RNA, treinamento da RNA, aplicação de métricas de desempenho e testes e análise dos resultados.

3.1 Identificação da pesquisa

Em relação à sua natureza, a pesquisa pode ser considerada como pesquisa básica. Neste tipo de pesquisa, busca-se aquisição e divulgação do conhecimento sem finalidades imediatas.

Quanto aos objetivos, a pesquisa tem caráter exploratório. Neste sentido, a finalidade da pesquisa é a descoberta de práticas ou diretrizes que precisam ser modificadas e obtenção de alternativas ao conhecimento científico existente.

Sobre a forma de abordagem, caracteriza-se como pesquisa quantitativa. Neste método, ocorre o emprego da quantificação, tanto na coleta de dados, quanto em seu tratamento e análise. Busca-se assim aumentar a precisão dos resultados esperados.

3.2 Definição de entradas

RNAs são treinadas a partir de diferentes e múltiplos valores de entrada. Selecionar as entradas corretas é muito importante para as técnicas de aprendizado de máquina. Ao modelar e definir a RNA do problema em questão, além das cota-

ções de preços, outras entradas podem ser consideradas para enriquecimento das generalizações. A justificativa para o uso de diferentes e múltiplas entradas é buscar uma forma da RNA encontrar interdependências entre componentes das séries temporais.

De acordo com Atsalakis e Valavanis (2009), que realizaram um estudo sobre a predição acionária, os tipos de entradas mais comuns são os valores de abertura e fechamento, máximo e mínimo diários atingidos e também o volume de negociações. Indicadores técnicos calculados a partir dos dados acima citados também são constantemente utilizados e foram considerados. Dessa forma, para presente trabalho, foram definidas as seguintes entradas a serem utilizadas na RNA:

1. Abertura: preço de abertura no dia
2. Máximo: preço máximo negociado no dia
3. Mínimo: preço mínimo negociado no dia
4. Fechamento: preço de fechamento do dia anterior
5. Volume: número de negociações do papel no dia
6. Índice de força relativa (IFR): o IFR mede a evolução da relação de forças entre compradores e vendedores ao longo do tempo. Os valores são compreendidos no intervalo de 0 a 100.

$$IFR = 100 - \frac{100}{1 + RS} \quad (3.1)$$

Onde:

- IFR = índice de Força Relativa;
- RS = média de altas no período / média de baixas no período.

Usualmente adota-se o período 14 dias para análise. Para se calcular a média de altas no período, soma-se a diferença entre o fechamento atual e o fechamento anterior de todos os dias que o fechamento foi positivo e divide-se pelo período. Para calcular a média de baixas no período, realiza-se o procedimento inverso. Uma interpretação comum do IFR, diz que se o indicador ultrapassa o valor de 70, um topo no mercado está sendo atingido, indicando uma posição para venda de papeis. Se o valor desce abaixo de 30, uma tendência de queda está para ser revertida, indicando uma posição para compra de papeis.

7. Média móvel aritmética de 10 dias (MMA10): também chamada de média móvel simples, a média móvel aritmética fornece o valor médio de uma cotação no intervalo de tempo de 10 dias. Ela é caracterizada como “móvel” pois a cada valor incluído no cálculo da média, o valor mais antigo é excluído. O indicador é utilizado pela análise técnica para identificar tendências, caracterizando-se usualmente como um ponto de suporte em caso de mercado em ascensão, ou ponto de resistência em caso de mercado em baixa.

$$MMA10 = \frac{fech(x) + fech(x-1) + fech(x-2) + \dots + fech(x-9)}{10} \quad (3.2)$$

Onde:

- MMA10 = média móvel aritmética de 10 dias;
- $fech(x)$ = preço de fechamento no dia x de referência.

8. Média móvel exponencial de 10 dias (MME10): trata-se de média móvel similar à média aritmética porém o indicador dá mais ênfase aos valores mais recentes, dando pesos maiores a esses valores, e menores aos mais antigos. Os pesos mais antigos caem de forma exponencial, de onde vem o

nome da média.

$$MME(x) = MME(x-1) + K[fech(x) - MME(x-1)] \quad (3.3)$$

Onde:

- $MME(x)$ = média móvel exponencial no dia x ;
- $fech(x)$ = preço de fechamento no dia x de referência.;
- K = constante de valor $2/(N+1)$, No caso, adota-se $K = 2/(10+1) = 0,18181818...$;
- N = número de dias para qual se quer o cálculo. No caso $N = 10$.

Para a análise técnica, uma interpretação comumente utilizada diz que existe uma tendência de venda de um ativo quando seu preço cruzar de cima para baixo a sua média móvel. Da mesma forma, existe uma tendência de compra quando seu preço cruzar de baixo para cima a sua média móvel (ADVFN, 2013b).

9. Média móvel exponencial de 12 dias ($MME[12]$): similar à média explicada anteriormente com a diferença de que o período N analisado vale 12. Na MME o valor de N a ser escolhido depende do tipo análise a ser feita, podendo variar do curtíssimo ao longo prazo.
10. Média móvel exponencial de 26 dias ($MME([6])$): média móvel exponencial com um prazo maior, no caso com valor de $N = 26$.

A Figura 3.1 apresenta um gráfico demonstrando um comparativo entre médias móveis de 10, 12 e 26 dias em relação aos fechamentos do papel Petrobras PN (PETR4).

11. MACD (*Moving Average Convergence Divergence*): indicador que se preocupa com a divergência e convergência das médias móveis. Formado pela



Figura 3.1: Exemplo de médias móveis exponenciais de 10, 12 e 26 dias do papel Petrobras PN (PETR4)

diferença entre duas médias móveis exponenciais, sendo uma de longo prazo e outra de curto prazo. Para o presente trabalho, o indicador MACD foi calculado subtraindo o valor obtido de uma média móvel exponencial de 26 dias (MME(26)) ao valor obtido da média móvel exponencial de 12 dias (MME[12]).

$$MACD = MME[12] - MME[26] \quad (3.4)$$

Onde:

- MACD = convergência e divergências das médias móveis;
- MME[x] = média móvel exponencial de x dias.

O MACD oscila acima ou abaixo de zero, sem qualquer limite superior ou inferior, respondendo às mudanças de preços relativamente rápidas. Para a análise técnica, uma interpretação comum diz que para um indicador MACD maior que zero, mostra que média móvel exponencial de curto prazo está maior que o valor de uma média móvel exponencial de longo prazo, evidenciando que as expectativas mais recentes são mais favoráveis para alta que as anteriores. A interpretação inversa também é válida. O valor zero

no MACD representa um intervalo no qual a oferta e a demanda estão em equilíbrio no mercado (ADVFN, 2013a).

12. Oscilador estocástico %K: indicador que mostra a relação entre o preço de fechamento de uma ação e suas máximas e mínimas durante certo período de tempo. O oscilador estocástico %K é formado através da divisão entre a diferença do preço de fechamento corrente e a menor mínima do período considerado e a diferença entre a maior máxima e a menor mínima.

$$\%K = \frac{fech(x) - menormnimo}{maiormaximo - (menormnimo * 100)} \quad (3.5)$$

Onde:

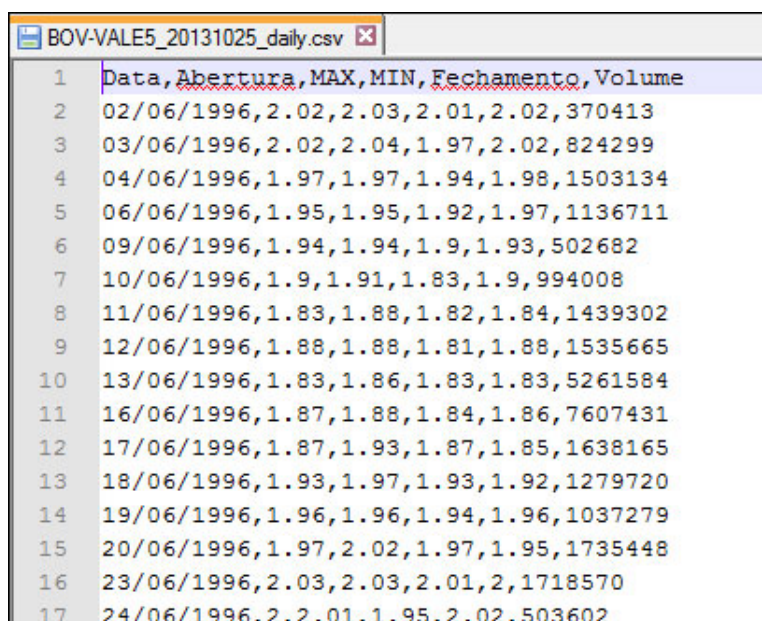
- %K = Oscilador estocástico %K;
 - fech(x) = preço de fechamento no dia x de referência;
 - menormnimo = menor valor negociado em um período de 14 dias;
 - maiormaximo = maior valor negociado em um período de 14 dias.
13. Oscilador estocástico %D: trata-se da média móvel aritmética de três dias do oscilador estocástico %K. Tanto o oscilador estocástico %K quanto o %D são usados para tentar definir as direções dos preços, além de antever padrões de alta e de baixa.

Com o total de treze entradas definidas, partiu-se para a coleta dos dados necessários para composição dos valores de interesse.

3.3 Coleta de dados

RNAs com objetivos de predição em séries temporais de preços são treinadas a partir dos dados históricos. Para tal, a título de critério de seleção, as séries históricas

dos cinco papéis mais negociados na BMF&Bovespa no ano de 2012 foram consideradas. Assim, os papéis a serem estudados são: Vale PNA (VALE5), Petrobrás PN (PETR4), Itau Unibanco PN (ITUB4), OGX Petróleo (OGXP3), Bradesco ON (BBDC4). Os dados em sua forma bruta estavam caracterizados como na Figura 3.2.



	Data	Abertura	MAX	MIN	Fechamento	Volume
2	02/06/1996	2.02	2.03	2.01	2.02	370413
3	03/06/1996	2.02	2.04	1.97	2.02	824299
4	04/06/1996	1.97	1.97	1.94	1.98	1503134
5	06/06/1996	1.95	1.95	1.92	1.97	1136711
6	09/06/1996	1.94	1.94	1.9	1.93	502682
7	10/06/1996	1.9	1.91	1.83	1.9	994008
8	11/06/1996	1.83	1.88	1.82	1.84	1439302
9	12/06/1996	1.88	1.88	1.81	1.88	1535665
10	13/06/1996	1.83	1.86	1.83	1.83	5261584
11	16/06/1996	1.87	1.88	1.84	1.86	7607431
12	17/06/1996	1.87	1.93	1.87	1.85	1638165
13	18/06/1996	1.93	1.97	1.93	1.92	1279720
14	19/06/1996	1.96	1.96	1.94	1.96	1037279
15	20/06/1996	1.97	2.02	1.97	1.95	1735448
16	23/06/1996	2.03	2.03	2.01	2	1718570
17	24/06/1996	2	2.01	1.95	2.02	503602

Figura 3.2: Exemplo de dados coletados em sua forma bruta

As séries históricas são oriundas do sítio ADVFN Brasil¹, um portal informativo sobre investimentos acionário em nível global. O portal fornece a evolução histórica dos papéis desde o surgimento dos mesmos. As séries históricas são disponibilizadas em arquivos com valores separados por vírgulas (*.csv) contendo a data de negociação, valor de abertura, valores máximo e mínimo atingidos, valor de fechamento e o volume de negociações. Os intervalos dos dados em seu estado bruto são descritos a seguir:

- Bradesco ON (BBDC4): 07/10/2001 a 24/10/2013

¹Disponível em <http://www.adfn.com/>.

- Itau Unibanco PN (ITUB4): 03/01/1993 a 24/10/2013
- OGX Petróleo (OGXP3): 21/12/2009 a 24/10/2013
- Petrobrás PN (PETR4): 07/10/1991 a 24/10/2013
- Vale PNA (VALE5): 02/06/1996 a 24/10/2013

Com os dados disponíveis, a próxima etapa foi calcular os devidos indicadores técnicos que serão utilizados como entradas na RNA.

3.4 Cálculo dos indicadores técnicos

Os indicadores técnicos foram calculados com ajuda do gerenciador de planilhas *Microsoft Excel*². Visando aumentar as possibilidades para as fases futuras da metodologia, principalmente modelagem e testes da RNA, os indicadores foram calculados para todos os períodos coletados. Dessa forma, quando futuramente fosse necessário observar o comportamento da RNA em diferentes períodos de tempo não seria necessário voltar à presente etapa. A Figura 3.3 mostra um trecho da planilha de cálculo de indicadores.

3.5 Escolha do ambiente de desenvolvimento

Objetivando encontrar um ambiente de desenvolvimento que melhor se adequasse ao problema tratado, três opções presentes em estudos relacionados foram analisadas em uso: *Matlab Neural Network Toolbox*³, *Neuroph Java Neural Network Framework*⁴ e *Weka* ⁵.

O ambiente de desenvolvimento escolhido para modelar, treinar e testar a RNA foi o *Matlab* da empresa *Mathworks* com o seu módulo *Neural Network*

²Disponível em <http://office.microsoft.com/>.

³Disponível em <http://www.mathworks.com/products/neural-network/>.

⁴Disponível em <http://neuroph.sourceforge.net/>.

⁵Disponível em <http://www.cs.waikato.ac.nz/ml/weka/>.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	Data	Abertura	MAX	MIN	Fechar	Volume	IFR	MMA10	MME10	MME12	MME26	MACD	Estocástico	Estocástico D
2	01/02/2010	17,3	17,55	16,35	17,3	20195100	36,91	17,88	17,64	17,68	17,76	-0,08	0,51	0,33
3	02/02/2010	17,64	17,9	17,42	17,9	14550600	40,30	17,76	17,69	17,71	17,77	-0,06	0,90	0,53
4	03/02/2010	18,15	19	18,03	19	33836500	47,30	17,73	17,93	17,91	17,87	0,05	1,00	0,80
5	04/02/2010	18,75	18,94	17,2	17,65	27261200	43,25	17,64	17,88	17,87	17,85	0,02	0,49	0,80
6	05/02/2010	17	18,14	16,81	18,14	31669400	48,51	17,71	17,93	17,91	17,87	0,04	0,68	0,72
7	08/02/2010	18,25	18,25	17,6	17,6	18134900	40,32	17,70	17,87	17,86	17,85	0,01	0,36	0,51
8	09/02/2010	18,05	18,25	17,4	17,4	24511900	38,47	17,67	17,78	17,79	17,82	-0,02	0,27	0,44
9	10/02/2010	17,7	17,77	17,17	17,55	16740000	43,63	17,69	17,74	17,76	17,80	-0,04	0,35	0,33
10	11/02/2010	17,55	17,89	17,18	17,83	16943100	52,55	17,72	17,76	17,77	17,80	-0,03	0,71	0,44
11	12/02/2010	17,69	17,75	17,28	17,53	10445900	49,36	17,79	17,71	17,73	17,78	-0,05	0,33	0,46
12	17/02/2010	17,9	17,95	17,55	17,65	10897300	49,65	17,83	17,70	17,72	17,77	-0,05	0,44	0,50
13	18/02/2010	17,55	17,75	17,4	17,6	11476900	51,93	17,80	17,68	17,70	17,76	-0,06	0,55	0,44
14	19/02/2010	17,41	17,57	17,21	17,21	10799600	47,16	17,62	17,60	17,62	17,72	-0,09	0,04	0,34
15	22/02/2010	17,35	17,5	16,9	16,9	15157400	50,78	17,54	17,47	17,51	17,66	-0,14	0,00	0,20
16	23/02/2010	16,74	16,84	16,26	16,4	24749100	42,95	17,37	17,28	17,34	17,56	-0,22	0,08	0,04
17	24/02/2010	16,65	16,74	16,3	16,31	13439900	36,46	17,24	17,10	17,18	17,47	-0,29	0,03	0,04
18	25/02/2010	16	16,25	15,76	15,89	23442500	20,04	17,09	16,88	16,98	17,35	-0,37	0,07	0,06
19	26/02/2010	16,1	16,18	15,75	15,75	15272500	26,13	16,91	16,67	16,79	17,23	-0,44	0,00	0,04
20	01/03/2010	16	16,38	15,81	16,32	18158000	27,59	16,76	16,61	16,72	17,17	-0,45	0,52	0,20
21	02/03/2010	16,6	16,83	16,03	16,05	27302500	29,55	16,61	16,51	16,62	17,08	-0,47	0,28	0,27
22	03/03/2010	16,1	16,54	15,95	16,11	21317500	32,33	16,45	16,44	16,54	17,01	-0,47	0,33	0,38

Figura 3.3: Trecho da planilha contendo o resultado do cálculo de indicadores para o papel OGP3

Toolbox. Através da observação da literatura, verificou-se casos de modelagens bem-sucedidas com ambiente escolhido. Além disso, o Matlab fornece visualizações múltiplas e flexíveis de resultados, suporte nativo à técnica de regularização bayesiana (conforme mostrado na Figura 3.4) e vasta documentação de suporte, fatores fundamentais para a escolha em confronto com as demais opções. A Figura 3.5 mostra a interface auxiliar de estruturação de redes neurais no *Matlab*.

O *Matlab* é um *software* interativo de alta performance voltado para o cálculo numérico. O *software* integra análise numérica, cálculo com matrizes, processamento de sinais e construção de gráficos em ambiente intuitivo no qual problemas e soluções são expressos somente como eles são escritos matematicamente, ao contrário da programação tradicional.

Neural Network ToolboxTM é um módulo do *Matlab* voltado exclusivamente para o trabalho com redes neurais. Com o módulo é possível modelar, treinar, visualizar e simular redes neurais. *Neural Network ToolboxTM* suporta as mais diversas aplicações de redes neurais, tais como reconhecimento de padrões, clusterização, predição de séries temporais e sistemas dinâmicos de modelagem e controle.

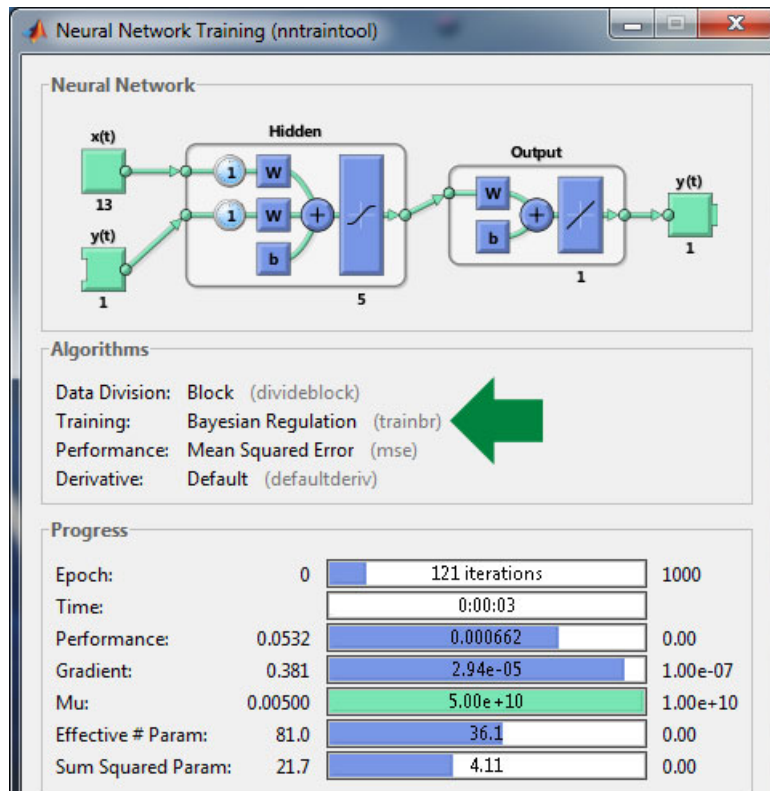


Figura 3.4: Suporte nativo à técnica de regularização bayesiana no Matlab

3.6 Preparação dos dados

Os dados de interesse para criar o modelo ideal de previsão da RNA foram importados para o ambiente de desenvolvimento através da interface mostrada em Figura 3.6. Dessa forma, conjuntos de dados de diferentes magnitudes foram importados para se observar os primeiros comportamentos em treinamento, baseando-se principalmente nas oscilações da Equação (2.1), o erro quadrático médio.

A função de ativação tangente hiperbólica, utilizada no modelo de RNA proposto, processa somente valores compreendidos no intervalo numérico $[-1,1]$. Sendo assim, os dados utilizados precisaram passar por um processo de normalização. Para tal, utilizou-se a função *mapminmax* do ambiente de desenvolvimento *Matlab*.

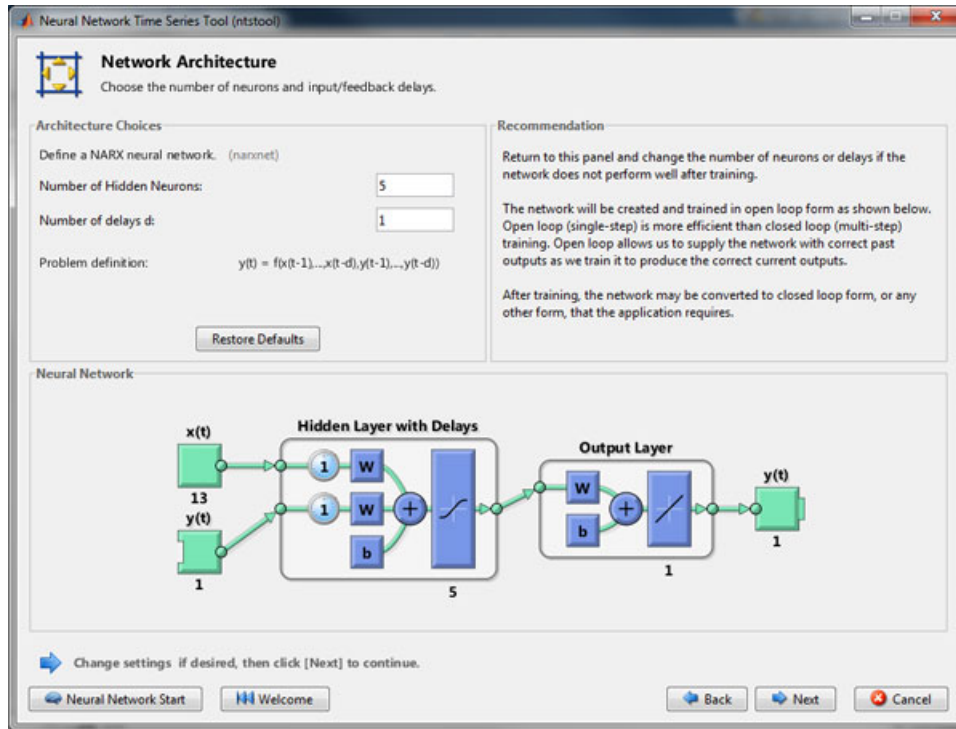


Figura 3.5: Interface auxiliar para estruturação de redes neurais no Matlab

$$mapminmax(y) = \frac{(y_{max} - y_{min})(x - x_{min})}{(x_{max} - x_{min}) + y_{min}} \quad (3.6)$$

Onde:

- y_{max} = valor máximo do intervalo, no caso $y_{max} = 1$
- y_{min} = valor mínimo do intervalo, no caso $y_{min} = -1$
- x = valor a ser processado
- x_{max} = valor máximo dentre o conjunto numérico
- x_{min} = valor mínimo dentre o conjunto numérico

Desta forma, utilizando o *Matlab* e os dados já normalizados, montou-se a matriz de entrada, representados pelas 13 entradas pré-definidas e a matriz alvo, representado pelos valores de fechamento do dia seguinte do papel.

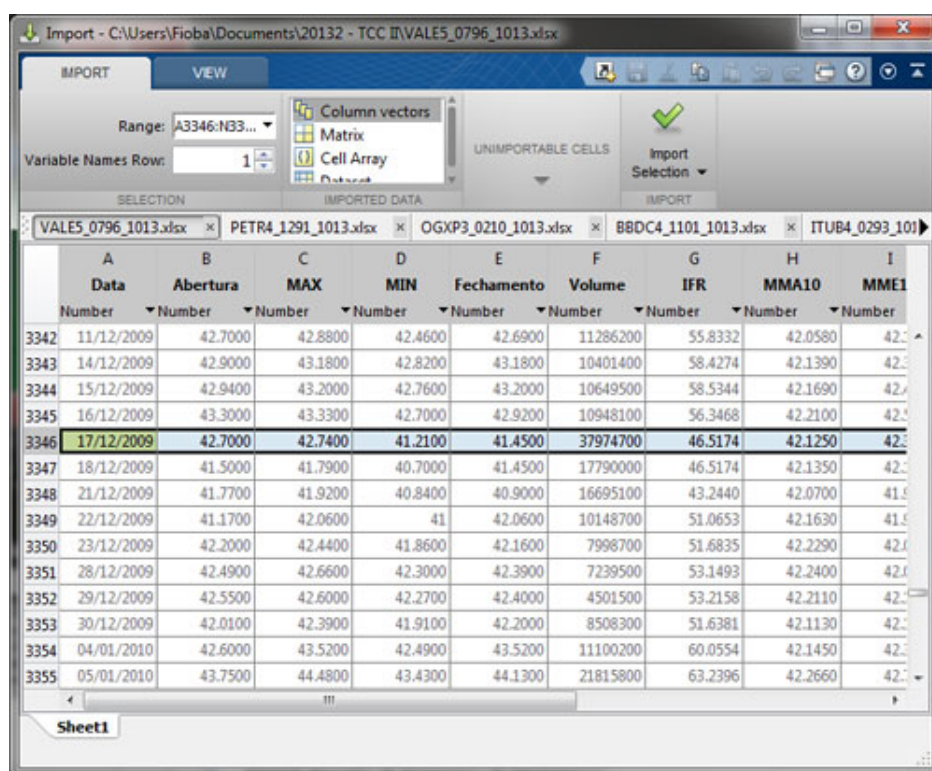


Figura 3.6: Ambiente de importação de dados no Matlab

3.7 Modelagem da RNA

Conforme concluído por Atsalakis e Valavanis (2009) em pesquisa em mais de 100 artigos publicados sobre o uso de redes neurais para predição de séries temporais, as maiores divergências e dificuldades dos pesquisadores é definir a estrutura da RNA, o modelo de previsão. Para o autor, até então trata-se de uma questão composta por procedimentos de tentativa e erro.

O tipo de rede neural escolhida, baseada na revisão da literatura, foi a *feedforward* com três camadas, na qual cada camada se conecta à próxima camada, porém não há caminho de volta. A camada de entrada foi composta por 13 neurônios sendo 5 valores de transações diárias (abertura, máximo, mínimo, fechamento e volume) e mais 8 indicadores originários da análise técnica.

Para a camada intermediária, também chamada de camada oculta, 6 neurônios foram definidos. Considerou-se a variação da Equação (2.1) para a amostra de dados destinada a testes, os resultados das primeiras experimentações e o tempo para treinamento da rede, conforme observável na Tabela 3.1 e na Tabela 3.2.

Tabela 3.1: OGXP3 - Definição do número de neurônios na camada oculta

Número de neurônios	MSE
1	0.0040
2	0.0029
3	0.0028
4	0.0030
5	0.0029
6	0.0028
7	0.0028
8	0.0029
9	0.0029
10	0.0028

Tabela 3.2: VALE5 - Definição do número de neurônios na camada oculta

Número de neurônios	MSE
1	0.0020
2	0.0016
3	0.0017
4	0.0016
5	0.0013
6	0.0013
7	0.0012
8	0.0015
9	0.0015
10	0.0014

Para o modelo de previsão sugerido e baseando-se somente a amostragem destinada a testes, de acordo com a Tabela 3.1 (OGXP3) e a Tabela 3.2 (VALE5), percebeu-se que um número maior de neurônios não necessariamente significou uma redução significativa do valor do MSE e ainda aumentou o tempo de processamento devido a maior quantidade de conexões sinápticas.

A camada de saída, responsável pelas saídas previsionadas, é composta por um neurônio, representado pelo preço de fechamento do papel do dia seguinte em referência aos valores de entrada. O modelo resultante está exposto na Figura 3.7.




Figura 3.7: Modelo de RNA: 3 camadas contendo 13 neurônios na camada de entrada, 6 neurônios na camada intermediária e 1 neurônio na camada de saída

A função de ativação *tansig* (tangente hiperbólica sigmóide) foi escolhida para a ativação entre os neurônios. A característica da função em permitir uma transição gradual entre dois estados e poderio analítico ganho para dados não-lineares motivaram a escolha. Os pesos entre as camadas da rede foram otimizados baseados na Equação (2.1).

3.8 Treinamento da RNA

A partir do modelo de previsão definido, iniciou-se a fase de treinamento e testes da RNA. Para cada papel estudado, amostras de diferentes magnitudes foram consideradas, com objetivo de observar o comportamento da rede nas mais diversas situações e enriquecer o estudo. A Tabela 3.3 mostra como o período das séries foi determinado:

Diferentes intervalos de amostragem do papel VALE5 foram considerados, observando-se os melhores desempenhos do MSE alcançados durante o treinamento. No período de janeiro de 2011 até setembro de 2013, compreendendo 682 dias de negociação, a RNA apresentou MSE de 0.00062255, o menor erro

Tabela 3.3: VALE5 - Definição de período de dados

Início	Fim	Dias de negociação	MSE
<i>Jan/10</i>	<i>Set/13</i>	930	0.00062255
<i>Jan/11</i>	<i>Set/13</i>	682	0.00060618
<i>Jan/12</i>	<i>Set/13</i>	434	0.00126650
<i>Jan/13</i>	<i>Set/13</i>	187	0.00143010

médio quadrático dentre os períodos analisados. Observou-se também que quanto menor o período, maior o MSE, diminuindo a capacidade de generalização da rede. O período de janeiro de 2010 até setembro de 2013 apresentou MSE superior à série de 682 dias. Desta forma, convencionou-se que o período aproximado de 682 dias iniciando-se em 01 de janeiro de 2011 e terminando em 30 de setembro de 2013 seria utilizado para os demais estudos.

Das amostras a serem consideradas, definiu-se também que 80% dos dados seriam utilizadas para treinamento e 20% para testes, buscando a acurácia do valor de fechamento do dia seguinte do papel. Assim, os dados compreendidos entre 03 de janeiro de 2011 até 18 de março de 2013 (546 registros) seriam destinados ao treinamento e de 19 de março de 2013 até 30 de setembro 2013 (136 registros) seriam destinados aos testes.

3.9 Aplicação de métrica de desempenho

Durante o período de modelagem e treinamento da RNA, a métrica de desempenho utilizada para se chegar ao modelo de previsão foi o MSE, representado pela Equação (2.1). Já para a análise dos resultados, escolheu-se a métrica Percentual de Acurácia de Acerto, que avalia a relação entre saídas e valores desejáveis. Tal métrica foi utilizada em estudos similares como o de Roque (2009).

Com auxílio do gerenciador de planilhas *Microsoft Excel*, uma planilha de análise contendo dados previsionados e dados reais foi criada. Definiu-se, então, margens de tolerância entre as quais os erros de previsão seriam tidos como

aceitáveis: 1%, 2%, 3%, 4% e 5% para mais ou para menos. Comparou-se então os resultados das previsões, encaixando-os dentro das margens estabelecidas. Considerou-se como “acerto” os resultados dentro da margem e como “erro” os resultados fora da margem. Desta forma, chegou-se ao Percentual de Acurácia de Acerto.

3.10 Testes e análise dos resultados

Até se chegar ao modelo de previsão proposto, uma série de testes foram feitos alterando-se de maneira controlada os diversos parâmetros e observando o comportamento da rede buscando a “RNA ideal”. Com o modelo definido, a rede recebe a matriz de entrada, faz todo o processamento e compara a saída com a matriz alvo do período analisado, avaliando os erros de estimativa sempre que necessário. Dessa forma, quanto maior a maturidade dos testes, menor a necessidade de alteração de algum parâmetro e mais claramente os resultados podem ser analisados.

Na etapa de análise dos resultados, verificou-se a conformidade com os objetivos do trabalho e o poder de previsão da RNA. Buscou-se também identificar em quais situações, para que tipos de papéis e em que condições de mercado a RNA alcançaria resultados mais satisfatórios.

4 RESULTADOS E DISCUSSÃO

Este capítulo apresenta e discute os resultados conseguidos aplicando-se a metodologia apresentada no capítulo 3. Apresenta-se a princípio informações sobre a aplicação da regularização *bayesiana* e posteriormente a discussão para diversos cenários de interesse criados.

4.1 Aplicação da Regularização *Bayesiana*

Durante a fase de treinamento, a regularização *bayesiana* foi aplicada na RNA com o intuito principal de aprimorar a capacidade de generalização. A Tabela 4.1 mostra os resultados do cálculo do MSE para redes com e sem aplicação da regularização *bayesiana*. Comparou-se os dados em confronto com outro algoritmo muito comum para treinamento de redes: Levenberg-Marquardt sem regularização.

Tabela 4.1: Comparação Regularização Bayesiana x Levenberg-Marquardt sem regularização

Ativo	MSE com regularizacao	MSE Levenberg-Marquardt sem regularização
<i>BDBC4</i>	0.00133870	0.00145270
<i>ITUB4</i>	0.00143630	0.00145090
<i>OGXP3</i>	0.00029511	0.00035227
<i>PETR4</i>	0.00080470	0.00143960
<i>VALE5</i>	0.00061117	0.00129430

Em todos os ativos analisados com o modelo de previsão, a aplicação da regularização *bayesiana* melhorou os erros quadráticos médios, evidenciando que a técnica mostra-se efetiva para aprimorar a capacidade de generalização da rede.

Nos histogramas mostrados na Figura 4.1 e na Figura 4.2, quanto mais erros próximos a zero, maior a quantidade de classificações próximas à linha central e melhor o desempenho alcançado pela rede. O eixo das abscissas é composto pelos erros (alvos - saidas) e o eixo das ordenadas pela quantidade de instâncias.




Figura 4.1: Histograma de erros sem regularização bayesiana

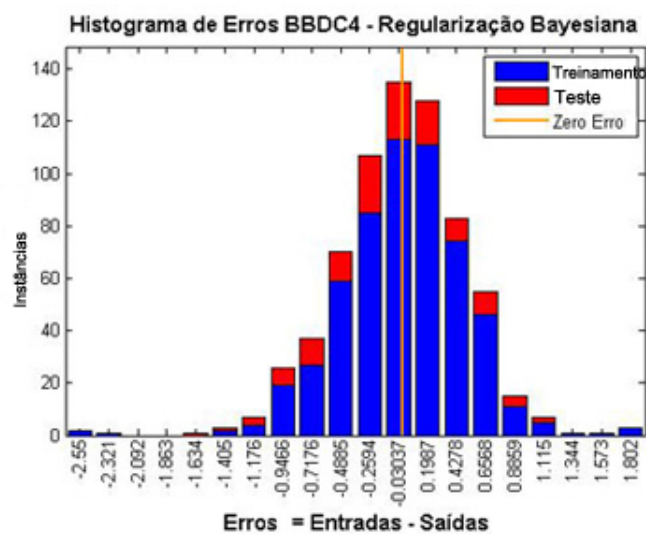


Figura 4.2: Histograma de erros com regularização bayesiana

Percebeu-se, através dos histogramas de erros com e sem regularização, que o número de ocorrências de erro próximos a zero é maior no histograma com regularização do que no histograma sem regularização. Além disto, as extremidades de erro sem regularização são maiores (entre -2.794 e 2.553) do que os erros

com regularização (entre -2.55 e 1.802), evidenciando um intervalo maior de ocorrência de erros para este último caso.

4.2 Cenários de estudo

A presente seção visa discutir acerca de cenários criados aplicando-se o modelo de previsão e efetuando testes na RNA para os diferentes papéis estudados. O estudo dos cenários é feito observando-se os resultados obtidos sobre o intervalo de dados destinado para testes, representado por 20% do total das séries.

4.2.1 Cenário I: BBDC4 no período de 03/01/2011 a 30/09/2013

Para o período analisado, caracterizado por um intervalo de 682 dias de negociação, a ação teve seu desempenho real executado conforme ilustrado na Figura 4.3. Trata-se de um período no qual o ativo sofreu um processo de desvalorização, tendo sua cotação caindo, em valores aproximados, de R\$ 27,00 para R\$ 19,00 ao final da série.

Para todo o período de teste, representados pelo trecho mostrado na Tabela 4.2, o percentual de acurácia ficou em 1,44% para mais ou para menos, representando um desvio médio de R\$ 0,44. Na avaliação de desempenho por percentual de acurácia, observando-se a Tabela 4.3 e a Figura 4.5, quase 50% dos dados ficaram compreendidos em uma margem de erro de 1 ponto percentual para mais ou para menos. Aproximadamente 90% das previsões ficaram compreendidas na margem de 3 pontos percentuais.

Observando a Figura 4.4 percebe-se que, no geral, a linha de previsão acompanha a linha desejável em praticamente todo o período, justificando a margem de erro de 1 ponto percentual para mais ou para menos em praticamente 50% da amostra de testes. A Figura 4.6 mostra taxas de acerto de previsão para o período de treinamento e de testes.




Figura 4.3: BBDC4 - Desempenho real da série temporal em todo o intervalo





Figura 4.4: BBDC4 - Comparação entre o desempenho desejável e o desempenho previsto no intervalo destinado à testes

Tabela 4.2: BBDC4 - Trecho da tabela com resultados das previsões no intervalo destinado à testes

Data	Desejável	Safda	Desvio abs.	Erro% abs
20/03/2013	35,89	35,87	0,02	0,06%
21/03/2013	35,83	35,75	0,08	0,21%
22/03/2013	35,40	35,68	0,28	0,78%
25/03/2013	32,62	35,42	2,80	8,59%
26/03/2013	33,33	32,64	0,69	2,06%
27/03/2013	34,14	33,44	0,70	2,06%
28/03/2013	33,80	33,52	0,28	0,84%
01/04/2013	33,40	33,52	0,12	0,37%
...%
26/09/2013	31,70	30,65	1,05	3,30%
27/09/2013	30,38	31,44	1,06	3,50%
30/09/2013	30,86	30,08	0,78	2,51%

Tabela 4.3: BBDC4 - Percentual de acurácia do intervalo destinado à testes

	$\pm 1\%$	$\pm 2\%$	$\pm 3\%$	$\pm 4\%$	$\pm 5\%$
<i>Acertos</i>	47,79%	70,59%	91,91%	97,06%	98,53%
<i>Erros</i>	52,21%	29,41%	8,09%	2,94%	1,47%

**Figura 4.5:** BBDC4 - Percentual de acurácia do intervalo destinado à testes

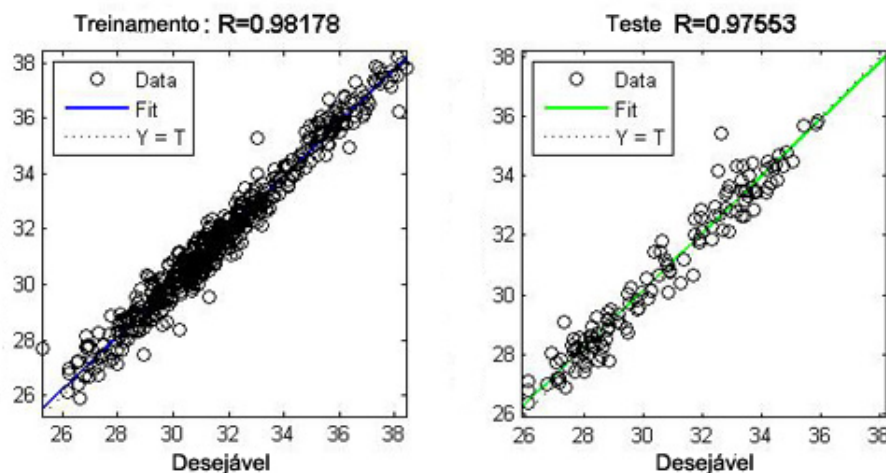


Figura 4.6: BBDC4 - Taxas de acerto de previsão para o período de treinamento e de testes

4.2.2 Cenário II: ITUB4 no período de 03/01/2011 a 30/09/2013

Para o período analisado, caracterizado por um intervalo de 682 dias de negociação, a ação teve seu desempenho real executado conforme ilustrado na Figura 4.7. Trata-se de um período no qual o ativo oscilou bastante em intervalos consideráveis com mínimos aproximados de R\$ 26,00 e picos aproximados em R\$ 40,00. Mesmo com as oscilações, ao término do período constatou-se desvalorização, tendo sua cotação caindo, em valores aproximados, de R\$ 38,00 para R\$ 32,00.

Para todo o período de teste, representados pelo trecho mostrado na Tabela 4.4, o percentual de acurácia ficou em 1,39% para mais ou para menos, representando um desvio médio de R\$ 0,43. Na avaliação de desempenho por percentual de acurácia, observando-se a Tabela 4.5 e a Figura 4.9, quase 50% dos dados ficaram compreendidos em uma margem de erro de 1 ponto percentual para mais ou para menos. Aproximadamente 92% das previsões ficaram compreendidas na margem de 3 pontos percentuais.

Observando a Figura 4.8 percebe-se que, no geral, a linha de previsão acompanha a linha desejável em praticamente todo o período, justificando a margem de erro de 1 ponto percentual para mais ou para menos em praticamente 50% da amostra de testes. A Figura 4.10 mostra taxas de acerto de previsão para o período de treinamento e de testes.

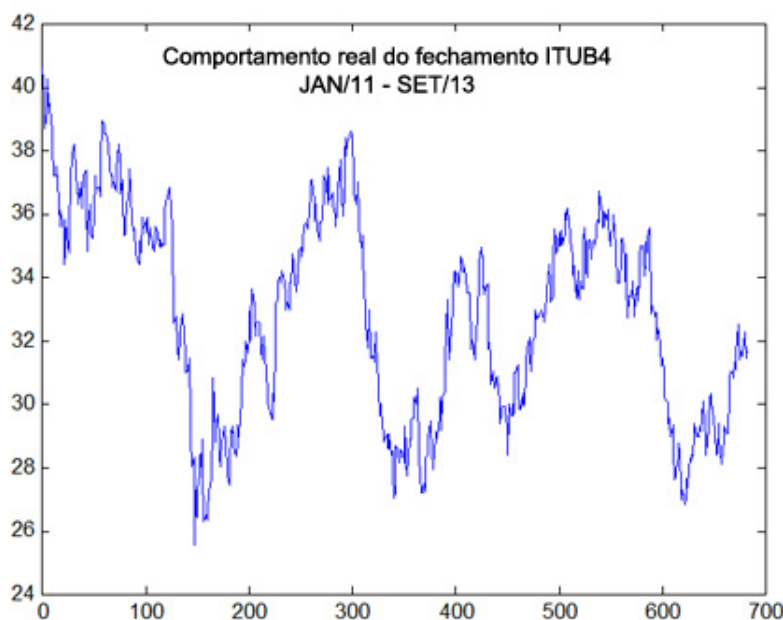


Figura 4.7: ITUB4 - Desempenho real da série temporal em todo o intervalo

4.2.3 Cenário III: OGXP3 no período de 01/02/2010 a 25/10/2012

Para o período analisado, caracterizado por um intervalo de 682 dias de negociação, a ação teve seu desempenho real executado conforme ilustrado na Figura 4.11. Dado o histórico recente do ativo, que sofreu brusca desvalorização, dados mais recentes (2013) não foram utilizados, pois a rede em certos momentos estimou previsões negativas, fugindo do domínio do problema e dificultando a interpretação. Trata-se de um período no qual o ativo sofreu forte queda, que levariam




Figura 4.8: ITUB4 - Comparação entre o desempenho desejável e o desempenho previsto no intervalo destinado à testes

Tabela 4.4: ITUB4 - Trecho da tabela com resultados das previsões no intervalo destinado à testes

Data	Desejável	Saída	Desvio abs.	Erro% abs.
20/03/2013	35,73	36,19	0,46	1,28%
21/03/2013	35,29	35,84	0,55	1,55%
22/03/2013	35,00	35,41	0,41	1,17%
25/03/2013	35,37	35,17	0,20	0,57%
26/03/2013	35,45	35,35	0,10	0,29%
27/03/2013	35,99	35,34	0,65	1,80%
28/03/2013	35,45	36,07	0,62	1,75%
01/04/2013	34,95	35,55	0,60	1,72%
...
26/09/2013	32,22	31,50	0,72	2,23%
27/09/2013	31,46	32,27	0,81	2,56%
30/09/2013	31,75	31,49	0,26	0,83%

Tabela 4.5: ITUB4 - Percentual de acurácia do intervalo destinado à testes

	$\pm 1\%$	$\pm 2\%$	$\pm 3\%$	$\pm 4\%$	$\pm 5\%$
Acertos	46,32%	73,53%	91,91%	98,53%	99,26%
Erros	53,68%	26,47%	8,09%	1,47%	0,74%

futuramente a valores que praticamente dissolveram o ativo. No início da série, o preço da ação estava cotado a aproximadamente R\$18,00, com picos de alta próximos




Figura 4.9: ITUB4 - Percentual de acurácia do intervalo destinado à testes

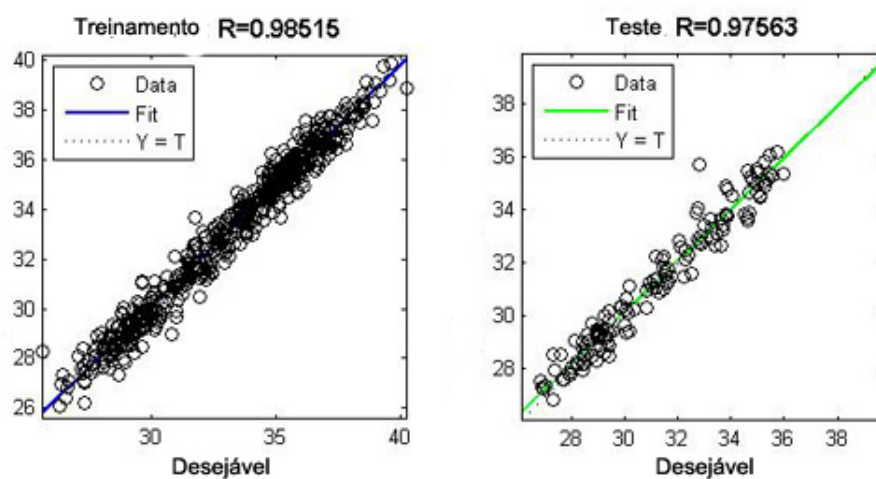


Figura 4.10: ITUB4 - Taxas de acerto de previsão para o período de treinamento e de testes

a R\$23,00. Ao término constatou-se a desvalorização, tendo sua cotação caindo, em valores aproximados, para R\$ 4,00.

Para todo o período de teste, representados pelo trecho mostrado na Tabela 4.6, o percentual de acurácia ficou em 13,56% para mais ou para menos, represen-

tando um desvio médio de R\$ 0,85. Na avaliação de desempenho por percentual de acurácia, observando-se a Tabela 4.7 e a Figura 4.13, aproximadamente 28% dos dados ficaram compreendidos margem de erro de 5 pontos percentuais para mais ou para menos, sendo a grande maioria dos erros em margens acima de 5%, evidenciando uma generalização não-aceitável para o escopo em questão.

Observando a Figura 4.12 percebe-se que a linha de previsão acompanha a linha desejável até o momento que ocorre uma forte queda do valor desejável em um período próximo ao fim do mês de junho de 2012. Após a referida queda, a linha de previsão não consegue acompanhar a linha desejável com erros considerados aceitáveis. A qualidade das previsões é comprometida a partir deste ponto, justificando a grande maioria dos erros em margens acima de 5%. A Figura 4.14 mostra taxas de acerto de previsão para o período de treinamento e de testes.




Figura 4.11: OGXP3 - Desempenho real da série temporal em todo o intervalo




Figura 4.12: OGXP3 - Comparação entre o desempenho desejável e o desempenho previsto no intervalo destinado à testes

Tabela 4.6: OGXP3 - Trecho da tabela com resultados das previsões no intervalo destinado à testes

Data	Desejável	Saída	Desvio abs.	Erro% abs.
16/04/2012	13,82	13,78	0,04	0,32%
17/04/2012	13,44	13,75	0,31	2,33%
18/04/2012	12,96	13,35	0,39	3,00%
19/04/2012	13,11	12,87	0,24	1,83%
20/04/2012	13,05	13,24	0,19	1,43%
23/04/2012	13,01	13,20	0,19	1,44%
24/04/2012	13,83	13,12	0,71	5,14%
25/04/2012	13,98	13,71	0,27	1,95%
...
23/10/2012	4,63	6,44	1,81	39,02%
24/10/2012	4,75	6,27	1,52	31,93%
25/10/2012	4,49	6,34	1,85	41,30%

Tabela 4.7: OGXP3 - Percentual de acurácia do intervalo destinado à testes

	±1%	±2%	±3%	±4%	±5%
Acertos	5,88%	11,03%	19,85%	22,79%	27,21%
Erros	94,12%	88,97%	80,15%	77,21%	72,79%




Figura 4.13: OGXP3 - Percentual de acurácia do intervalo destinado à testes

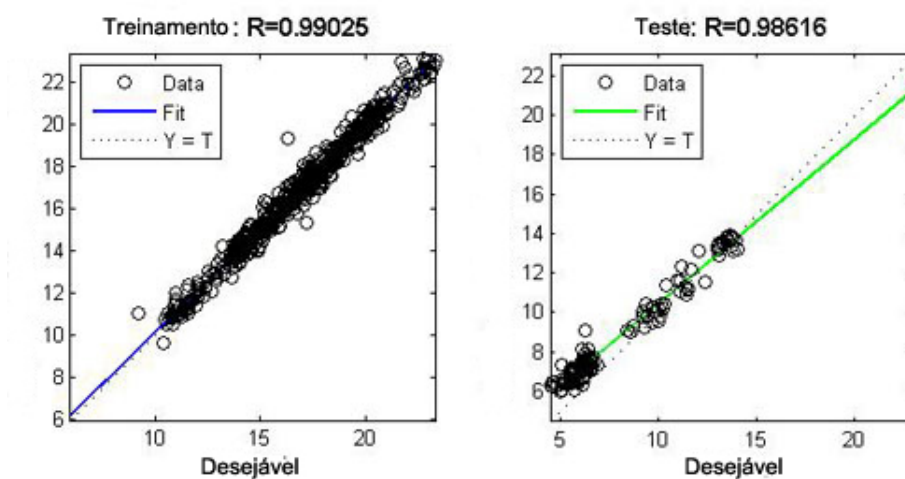


Figura 4.14: OGXP3 - Taxas de acerto de previsão para o período de treinamento e de testes

4.2.4 Cenário IV: PETR4 no período de 03/01/2011 a 30/09/2013

Para o período analisado, caracterizado por um intervalo de 682 dias de negociação, a ação teve seu desempenho real executado conforme ilustrado na Figura 4.15.

Trata-se de um período no qual o ativo oscilou bastante em margens razoáveis de aproximadamente R\$ 7,00 e com tendência predominante de queda à longo prazo. Mesmo com as oscilações, a força de baixa predominou e ao término do período constatou-se desvalorização, tendo sua cotação caindo, em valores aproximados, de R\$ 27,00 para R\$ 19,00.

Para todo o período de teste, representados pelo trecho mostrado na Tabela 4.8, o percentual de acurácia ficou em 2,75% para mais ou para menos, representando um desvio médio de R\$ 0,48. Na avaliação de desempenho por percentual de acurácia, observando-se a Tabela 4.9 e a Figura 4.17, quase 40% dos dados ficaram compreendidos em uma margem de erro de 2 pontos percentuais para mais ou para menos. Aproximadamente 89% das previsões ficaram compreendidas na margem de erro de 5 pontos percentuais.

Observando a Figura 4.16 percebe-se que a linha de previsão acompanha a linha desejável até o momento que ocorre uma forte queda do valor desejável em um período próximo ao fim do mês de junho de 2013 e início de julho de 2013. Após a referida queda, a linha de previsão até acompanha o valor desejável porém não mais com a mesma qualidade. Após uma recuperação do papel, por volta do início de setembro de 2013, as previsões voltam a ter uma margem de erro mais aceitável. A Figura 4.18 mostra taxas de acerto de previsão para o período de treinamento e de testes.

4.2.5 Cenário V: VALE5 no período de 03/01/2011 a 30/09/2013

Para o período analisado, caracterizado por um intervalo de 682 dias de negociação, a ação teve seu desempenho real executado conforme ilustrado na Figura 4.19. Trata-se de um período no qual o ativo sofreu um processo de desvalorização, tendo sua cotação caindo, em valores aproximados, de R\$ 51,00 para R\$ 31,00 ao final da série.




Figura 4.15: PETR4 - Desempenho real da série temporal em todo o intervalo




Figura 4.16: PETR4 - Comparação entre o desempenho desejável e o desempenho previsto no intervalo destinado à testes


Para todo o período de teste, representados pelo trecho mostrado na Tabela 4.10, o percentual de acurácia ficou em 2,62% para mais ou para menos, represen-

Tabela 4.8: PETR4 - Trecho da Tabela com resultados das previsões no intervalo destinado à testes

Data	Desejável	Saída	Desvio abs.	Erro% abs.
20/03/2013	18,53	19,06	0,53	2,84%
21/03/2013	18,63	18,82	0,19	1,01%
22/03/2013	18,63	19,01	0,38	2,03%
25/03/2013	18,59	19,10	0,51	2,73%
26/03/2013	18,42	19,05	0,63	3,41%
27/03/2013	18,35	18,86	0,51	2,80%
28/03/2013	18,04	18,76	0,72	3,98%
01/04/2013	17,70	18,44	0,74	4,18%
...
26/09/2013	18,36	19,03	0,67	3,67%
27/09/2013	18,67	18,96	0,29	1,53%
30/09/2013	18,78	19,25	0,47	2,51%

Tabela 4.9: PETR4 - Percentual de acurácia do intervalo destinado à testes

	$\pm 1\%$	$\pm 2\%$	$\pm 3\%$	$\pm 4\%$	$\pm 5\%$
<i>Acertos</i>	23,53%	40,44%	58,82%	76,47%	88,97%
<i>Erros</i>	76,47%	59,56%	41,18%	23,53%	11,03%

**Figura 4.17:** PETR4 - Percentual de acurácia do intervalo destinado à testes

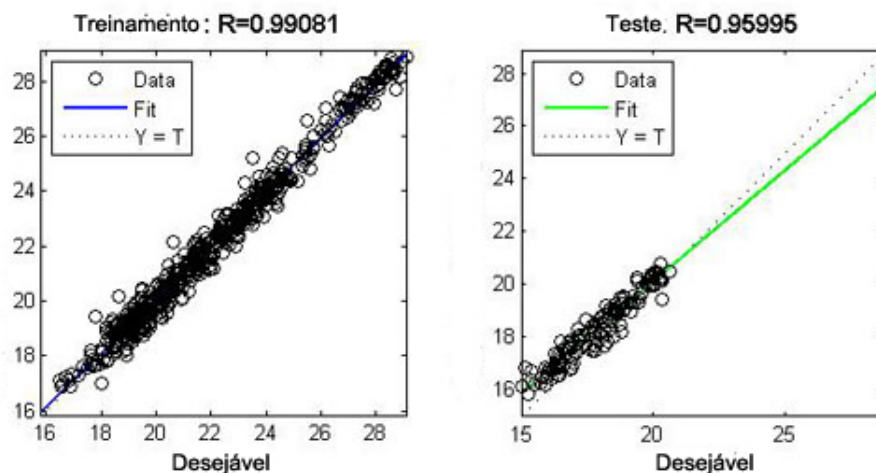


Figura 4.18: PETR4 - Taxas de acerto de previsão para o período de treinamento e de testes

tando um desvio médio de R\$ 0,78. Na avaliação de desempenho por percentual de acurácia, observando-se a Tabela 4.11 e a Figura 4.21, quase 50% dos dados ficaram compreendidos em uma margem de erro de 2 pontos percentuais para mais ou para menos. Aproximadamente 88% das previsões ficaram compreendidas na margem de 5 pontos percentuais.

Observando a Figura 4.20 percebe-se que a linha de previsão acompanha a linha desejável durante um período de quedas sucessivas, destoando de forma mais considerável em alguns trechos. Durante uma rápida recuperação na primeira quinzena de julho de 2013, as estimativas ficam superestimadas, porém logo em seguida voltam a apresentar saídas dentro de erros aceitáveis. A Figura 4.22 mostra taxas de acerto de previsão para o período de treinamento e de testes.

4.3 Discussão dos cenários

A presente seção discute acerca do desempenho do modelo de previsão proposto testado nos diferentes cenários apresentados.




Figura 4.19: VALE5 - Desempenho real da série temporal em todo o intervalo





Figura 4.20: VALE5 - Comparação entre o desempenho desejável e o desempenho previsto no intervalo destinado à testes

Tabela 4.10: VALE5 - Trecho da tabela com resultados das previsões no intervalo destinado à testes

Data	Desejável	Safda	Desvio abs.	Erro% abs
20/03/2013	33,18	33,20	0,02	0,06%
21/03/2013	32,95	33,44	0,49	1,50%
22/03/2013	32,64	33,08	0,44	1,34%
25/03/2013	32,99	32,86	0,13	0,39%
26/03/2013	33,63	33,42	0,21	0,62%
27/03/2013	33,24	33,83	0,59	1,78%
28/03/2013	32,41	33,65	1,24	3,84%
01/04/2013	31,84	32,79	0,95	2,98%
...
26/09/2013	32,14	32,84	0,70	2,17%
27/09/2013	31,54	32,70	1,16	3,69%
30/09/2013	31,86	32,43	0,57	1,78%

Tabela 4.11: VALE5 - Percentual de acurácia do intervalo destinado à testes

	$\pm 1\%$	$\pm 2\%$	$\pm 3\%$	$\pm 4\%$	$\pm 5\%$
Acertos	27,94%	48,53%	59,56%	76,47%	88,24%
Erros	72,06%	51,47%	40,44%	23,53%	11,76%

**Figura 4.21:** VALE5 - Percentual de acurácia do intervalo destinado à testes




Figura 4.22: VALE5 - Taxas de acerto de previsão para o período de treinamento e de testes

4.3.1 Previsões destoantes

Visando atender ao objetivo específico de identificar em quais condições e para quais tipos de situações a RNA apresenta melhores resultados, torna-se importante também observar as previsões que foram mais destoantes, responsáveis pelo aumento dos valores dos erros médios.

No cenário I (BBDC4), com média de erro em 1,44%, um erro na ordem de 8,59% ocorrido no dia 25/03/2013 destoa fortemente. Na referida data, as ações preferenciais do Bradesco S.A. sofreram um desdobramento (*split* da razão de 10 para 11). Sendo assim, a medida utilizada para aumentar a liquidez do papel, reflete no valor de fechamento e faz com que a rede erre de forma destoante.

No cenário II (ITUB4), com média de erro em 1,39%, um erro na ordem de 8,77% ocorrido no dia 20/05/2013 destoa fortemente. Na referida data, em Assembleia Geral Extraordinária, o Itau Unibanco, representado por seus acionistas, decidiu pelo aumento de seu capital social e distribuição de bonificações em ações à razão de 10% a todos os inscritos como proprietários da ação. Desta forma, a

decisão reflete no valor de fechamento e faz com que a rede erre de forma tão destoante.

No cenário III (OGXP3), com média de erro em 13,56%, dois erros na ordem de 44,73% e 45,01% ocorridos nos dias 26/06/2012 e 27/06/2012 destoam muito fortemente, podendo ser observados na Figura 4.23. Na referida data, os papéis passavam por um momento de desconfiança no mercado. “Nos dois últimos pregões, a ação da OGX derreteu quase 40%, após a empresa de petróleo e gás divulgar na noite de terça-feira dados de produção muito abaixo do esperado pelo mercado, levando analistas a questionar as bases do programa de crescimento das empresas do grupo” (G1ECONOMIA, 2012). Após uma queda tão brusca, os erros de previsão nas redes se tornaram menores, porém a qualidade das generalizações posteriores foi prejudicada.



Figura 4.23: OGXP3 - Momento de forte queda não-previsto pela rede

No cenário IV (PETR4), com média de erro em 2,75%, um erro na ordem de 11,00% ocorrido no dia 04/07/2013 destoa fortemente. Na referida data, as ações da Petrobras caíram ao menor valor em quase oito anos. “A queda das ações

ocorreram por temores de que o governo reduza o imposto de importação para uma série de produtos” (G1ECONOMIA, 2013).

No cenário V (VALE5), com média de erro em 2,62%, um erro na ordem de 10,61% ocorrido no dia 24/06/2013 destoa fortemente. Na referida data, as ações da Vale atingiram seu pior nível desde setembro de 2009. Segundo analistas, as preocupações com a economia chinesa fazem os papéis da empresa brasileira se desvalorizarem. “A China é a maior importadora do minério produzido pela Vale. O país está em uma situação financeira delicada, com medidas do banco central chinês para reduzir empréstimos a outros bancos, deixando os investidores preocupados. Uma crise econômica lá faria com que se reduzissem suas importações em geral, incluindo o minério da Vale” (UOLECONOMIA, 2013).

4.3.2 Erros médios

Com auxílio da métrica de desempenho Percentual de Acurácia de Acerto, verificou-se o erro percentual entre os valores previstos e os desejáveis. Observando os dados gerados na amostragem destinada à testes, chegou-se ao valor médio do erro para cada cenário, apresentado na Tabela 4.12.

Tabela 4.12: Erros médios entre cenários

Cenário	Erro médio (%)
<i>I – BBDC4</i>	1,44
<i>II – ITUB4</i>	1,39
<i>III – OGXP3</i>	13,56
<i>IV – PETR4</i>	2,75
<i>V – VALE5</i>	2,62

Para os períodos considerados, os cenários I e II, correspondente às empresas do setor bancário Bradesco e Itau/Unibanco apresentaram a melhor qualidade das previsões. O cenário III, da turbulenta OGX Petrolífera, apresentou erro médio fora do aceitável, muito em decorrência da sua saúde econômica no período. Os cenários IV e V, das sólidas Petrobras e Vale apresentaram algumas previsões

destoantes que influenciaram no erro, porém pode-se afirmar que a maioria das previsões foram alocadas em níveis de erro aceitáveis.

5 CONCLUSÕES

A vasta gama de variáveis que influenciam as cotações diárias de ações de empresas dos mais diversos segmentos, além das diferentes maneiras de se construir um modelo de rede neural para previsão, faz com que a predição no mercado acionário com auxílio de redes neurais artificiais apresente uma complexidade natural.

No mundo globalizado, as informações são difundidas em canais tecnológicos ágeis e as transações acionárias ocorrem através da *Internet*. Sendo assim, forma-se o alicerce para que fatores externos como, por exemplo, notícias, balanços, discursos e pacotes econômicos reflitam de forma imediata no preço das ações. Prever com precisão tais comportamentos é, com certeza, tarefa inimaginável. Por outro lado, o modelo de previsão apresentado neste trabalho, também gerou previsões dentro de margens de erros aceitáveis, o que é de grande valia para os investidores.

Para se chegar ao modelo de previsão utilizado, uma série de pequenas decisões foram tomadas com base na experimentação exaustiva sobre a rede e no estudo da literatura relacionada. Isto porque não há muita convenção acerca do número e tipos de entradas para a rede, algoritmos de treinamento, arquitetura da rede e períodos para amostragem. Sendo assim, as diferentes configurações montadas geram acurácias diferentes para cada tipo de ação. Seguindo a ideia de se realizar as melhores escolhas e aprimorar a acurácia das previsões, é importante ressaltar que a técnica de regularização *bayesiana*, baseada na sua proposta de evitar super-ajuste (*overfitting*) e sub-ajuste (*underfitting*), diminuiu o erro médio quadrático das previsões geradas pelo modelo de previsão proposto.

Dentre os cenários estudados no presente trabalho, o cenário correspondente ao papel da petrolífera OGX, apresentou as piores previsões da rede neural. Não obstante, durante o período estudado, a empresa passou por um período de enorme turbulência, desvalorização e desconfiança por parte dos investidores. Re-

sultados de produção abaixo dos projetados, balanços desfavoráveis e excesso de otimismo não puderam ser previstos pelo modelo de rede proposto.

Os cenários de estudo das empresas Vale e Petrobras mostram que o poder de previsão da rede neural pode ser abalado em alguns pontos-chave por influência externa, porém, devido a uma maior solidez das empresas em questão, as previsões em sua maioria estão encaixadas em margens de erro aceitáveis. Treinamentos em maior frequência podem minimizar o erro de futuras previsões.

Os cenários de estudo correspondentes às ações do Banco Bradesco e Itau/Unibanco apresentaram a maior quantidade de previsões dentro de margens de erro aceitáveis. As empresas do setor bancário apresentaram, para o período estudado, uma maior solidez e estabilidade. Sendo assim, o modelo de previsão mostra-se adequado para períodos em que as empresas estão maduras e em conformidade com suas projeções financeiras, ou seja, saudáveis em seu posicionamento no mercado.

Utilizar cegamente somente as redes neurais artificiais, em particular o modelo proposto, para prever comportamentos futuros é, com certeza, um grande equívoco por parte do investidor. O estudo mostra que o modelo utilizado em conjunto com informações oriundas da análise fundamentalista traz maior embasamento para as previsões. É importante para o investidor estar atento à saúde econômica da empresa a qual está se investindo e, assim, buscar o gerenciamento do risco. Modelos de previsão baseados em redes neurais artificiais podem ser implementados em *software*, funcionando como ferramenta auxiliar para a tomada de decisão do investidor.

Para trabalhos futuros, recomenda-se a variação do número e tipos de dados de entrada na primeira camada do modelo, mudanças no período de amostragem e comparação através do Percentual de Acurácia de Acerto. Dessa forma, aprimora-se o modelo de forma gradual e, conseqüentemente, ganha-se em qualidade das previsões. Para atenuar o impacto gerado por fatores externos de relevân-

cia, sugere-se apresentar de alguma forma este tipo de informação à rede. Agentes inteligentes que coletam informações em redes sociais e de fontes de dados não-estruturados como um todo podem ser aliados de preponderância para as RNAs. Outra sugestão seria utilizar o modelo proposto com dados de oscilações ainda mais curtos, como por exemplo, em janelas de 15, 30 e 60 minutos. Tais previsões ajudariam, fundamentalmente, os investidores que compram e vendem ações no mesmo dia, o chamado *intraday*.

REFERÊNCIAS BIBLIOGRÁFICAS

- ADVFN. *MACD*. 2013. <http://br.advfn.com/educacional/analise-tecnica/macd>. Acessado em 28/01/2014.
- ADVFN. *Média Móvel Exponencial*. 2013. <http://br.advfn.com/educacional/analise-tecnica/media-movel-exponencial>. Acessado em 28/01/2014.
- AHMADI, H. Testability of the arbitrage pricing theory by neural network. In: IEEE. *Neural Networks, 1990., 1990 IJCNN International Joint Conference on*. [S.l.], 1990. p. 385–393.
- ARAÚJO, E.; GAMA, C. *Replicando características de ciclos económicos: um estudo comparativo entre Redes Neurais Artificiais e modelos ARIMA*. [S.l.], 2004.
- ATSALAKIS, G. S.; VALAVANIS, K. P. Surveying stock market forecasting techniques – part ii: Soft computing methods. *Expert Systems with Applications*, v. 36, n. 3, Part 2, p. 5932 – 5941, 2009. ISSN 0957-4174. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0957417408004417>>.
- BARRETO, J. M. *Introdução às Redes Neurais Artificiais*. Santa Catarina: UFSC, 2002.
- BLANCO, A.; DELGADO, M.; PEGALAJAR, M. A real-coded genetic algorithm for training recurrent neural networks. *Neural networks*, Elsevier, v. 14, n. 1, p. 93–105, 2001.
- BMFBOVESPA. *Introdução ao Mercado de Capitais*. São Paulo, 2010. 44 p. Disponível em: <<http://www.bmfbovespa.com.br/pt-br/a-bmfbovespa/download/merccap.pdf>>.
- BMFBOVESPA. *Mercado de ações: conceitos fundamentais*. São Paulo, 2011. 12 p. Disponível em: <<http://www.bmfbovespa.com.br/Pdf/ConceitosFundamentais.pdf>>.
- COMISSÃO DE VALORES MOBILIÁRIOS. *O Mercado de Valores Mobiliários Brasileiro*. Rio de Janeiro, 2013. 351 p. Disponível em: <<http://www.portaldoinvestidor.gov.br/portaldoinvestidor/export/sites-/portaldoinvestidor/publicacao/Livro/LivroTOP-CVM.pdf>>.
- DEBASTIANI, C. A. *Análise técnica de ações-identificando oportunidades de compra e venda*. São Paulo: Novatec, 2008.
- DESCHATRE, G. A.; MAJER, A. *Aprenda a investir com sucesso em ações: análise técnica e fundamentalista*. [S.l.]: Ciência Moderna, 2006.

EXAME. *Como funciona a análise fundamentalista de ações.*

2010. <http://exame.abril.com.br/seu-dinheiro/noticias/como-funciona-analise-fundamentalista-acoes-576374/>. Acessado em 18/02/2014.

FORTUNA, E. *Mercado financeiro: produtos e serviços*. [S.l.]: Qualitymark, 2008.

GIECONOMIA. *Bovespa fecha em queda pressionada por novo tombo da OGX*. 2012. <http://g1.globo.com/economia/mercados/noticia/2012/06/bovespa-fecha-em-queda-pressionada-por-novo-tombo-da-ogx.html>. Acessado em 28/01/2014.

GIECONOMIA. *Ações da Petrobras caem ao menor valor em quase oito anos*. 2013. <http://g1.globo.com/economia/mercados/noticia/2013/07/acoes-da-petrobras-fecham-com-o-menor-valor-em-quase-oito-anos.html>. Acessado em 28/01/2014.

HAYKIN, S. S. *Neural networks: a comprehensive foundation*. [S.l.]: Prentice Hall Englewood Cliffs, NJ, 2007.

INVESTPEDIA. *Conceitos fundamentais sobre bolsa de valores*. 2009. <http://www.investpedia.com.br/artigo/Conceitos+fundamentais+sobre+bolsa+de+valores.aspx>. Acessado em 18/09/2013.

KAMIJO, K.-i.; TANIGAWA, T. Stock price pattern recognition-a recurrent neural network approach. In: IEEE. *Neural Networks, 1990., 1990 IJCNN International Joint Conference on*. [S.l.], 1990. p. 215–221.

KOHARA, K.; ISHIKAWA, T.; FUKUHARA, Y.; NAKAMURA, Y. Stock price prediction using prior knowledge and neural networks. *Intelligent systems in accounting, finance and management*, Wiley Online Library, v. 6, n. 1, p. 11–22, 1997.

LAWRENCE, S.; TSOI, A. C.; GILES, C. L. Noisy time series prediction using symbolic representation and recurrent neural network grammatical inference. 1998.

MACKAY, D. J. A practical bayesian framework for backpropagation networks. *Neural computation*, MIT Press, v. 4, n. 3, p. 448–472, 1992.

MCCLELLAND, J. L.; RUMELHART, D. E.; GROUP, P. R. *et al.* Parallel distributed processing. *Explorations in the microstructure of cognition*, v. 2, 1986.

MIAO, K.; CHEN, F.; ZHAO, Z.-g. Stock price forecast based on bacterial colony rbf neural network [j]. *Journal of Qingdao University (Natural Science Edition)*, v. 2, p. 011, 2007.

ROQUE, R. C. *Estudo sobre a empregabilidade da previsão do índice BOVESPA usando Redes Neurais Artificiais*. [S.l.]: Trabalho de conclusão de curso - Universidade Federal do Rio de Janeiro, 2009.

THOMÉ, A. C. Data warehouse, data mining. *Redes Neurais—Uma ferramenta para KDD e Data Mining*, 2002.

TICKNOR, J. L. A bayesian regularized artificial neural network for stock market forecasting. *Expert Systems with Applications*, v. 40, n. 14, p. 5501 – 5506, 2013. ISSN 0957-4174. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0957417413002509>>.

TRIPPI, R. R.; DESIENO, D. Trading equity index futures with a neural network. *The Journal of Portfolio Management*, Institutional Investor Journals, v. 19, n. 1, p. 27–33, 1992.

TSAIH, R.; HSU, Y.; LAI, C. C. Forecasting s&p 500 stock index futures with a hybrid ai system. *Decision Support Systems*, Elsevier, v. 23, n. 2, p. 161–174, 1998.

UOLECONOMIA. *Ações da Vale despencam e atingem pior nível desde setembro de 2009*. 2013.
<http://economia.uol.com.br/cotacoes/noticias/redacao/2013/06/24/acoes-da-vale-despencam-na-bolsa-pior-nivel-desde-setembro-de-2009.htm>. Acessado em 28/01/2014.

YOON, Y.; SWALES, G. Predicting stock price performance: A neural network approach. In: IEEE. *System Sciences, 1991. Proceedings of the Twenty-Fourth Annual Hawaii International Conference on*. [S.l.], 1991. v. 4, p. 156–162.